# Statistical Machine Learning

2주차

담당: 15기 염윤석



1. What is Supervised Learning?

2. Train model


3. Model Selection




# 1. What is Supervised Learning?



### Supervised Learning vs Unsupervised Learning















동일한 항목의 많은 재고가 있습니다. 다음 3달 동안 이러한 항목 중 몇 개가 판매될지 예측하려고 합니다.

#### → Regression or Classification

당신은 개별 고객 계정을 검사하는 소프트웨어를 만들려고 합니다. 각 계정에 대해 해킹/손상 여부를 결정하는 기능을 만들려고 합니다.

#### → Regression or Classification








# 2. Train Model



# Learning a Class



### Class C : Family car

→ Is this car x a family car? = classification task

Input representation:

X<sub>1</sub>:price, X<sub>2</sub>: engine power

#### "Learning a Class"


= input feature을 통해서 class를 서술하는 것

Output:

positive(+) or negative(-)



# Learning a Class



 $(p_1 \le \text{price} \le p_2) \& (e_1 \le \text{engine power} \le e_2)$ 

학습의 목표 : Class description → example classification

#### **Inductive Bias:**

- 학습이 가능도록 하기 위한 장치 → Aligned Rectangle
- 학습 시에는 만나보지 않았던 상황에 대하여 정확한 예측을 하기 위해 사용하는 추가적인 가정
- Parameter: {p1, p2, e1, e2}

!! 결국 classification을 위해서 {p1, p2, e1, e2} 만 찾으면 된다!!

수 많은 {p1, p2, e1, e2} 조합 = Hypothesis H = Assumption = Model

Q. 이 중에서 "최적"의 선택은 어떤 것...?



# Dimensions of a Supervised Learner

모델을 훈련한다. = Task를 이행하기 위해서, 훈련 데이터 셋에 가장 잘 맞도록 모델 파라미터를 설정

1. Model:

$$g(\mathbf{x} | \theta)$$

2. Loss function:

$$E(\theta \mid \mathcal{X}) = \sum_{t} L(r^{t}, g(\mathbf{x}^{t} \mid \theta))$$

3. Optimization procedure:  $\theta^* = \arg\min_{\alpha} E(\theta \mid X)$ 

$$\theta^* = \arg\min_{\theta} E(\theta \mid X)$$

모델을 설정.


정답을 가장 잘 맞추는 모델 파라미터를 찾는다.



### **Loss Function**

• What is Loss Function? 예측값과 실제값(레이블)의 차이를 구하는 기준

Quantifies the error between output of the algorithm and given target value.





### **Loss Function**

Loss function penalizes bad predictions.

### Regression

• Mean Squared Error

$$MSE = \frac{\sum_{i=1}^{n} (y_i - \hat{y}_i)^2}{n}$$

#### Others:

Mean absolute error and mean bias error

#### Classification

• Binary Cross Entropy

$$\textit{BCE} = -\frac{1}{N} \sum_{i=0}^{N} y_i \cdot \log(\hat{y_i}) + (1-y_i) \cdot \log(1-\hat{y_i})$$

Categorical Cross Entropy

$$\textit{CCE} = -\frac{1}{N} \sum_{i=0}^{N} \sum_{j=0}^{J} y_{j} \cdot \log(\hat{y_{j}}) + (1 - y_{j}) \cdot \log(1 - \hat{y_{j}})$$

#### Others:

Hinge loss / SVM loss.



# Dimensions of a Supervised Learner

모델을 훈련한다. = Task를 이행하기 위해서, 훈련 데이터 셋에 가장 잘 맞도록 모델 파라미터를 설정

1. Model:

$$g(\mathbf{x} | \theta)$$

2. Loss function:

$$E(\theta \mid \mathcal{X}) = \sum_{t} L(r^{t}, g(\mathbf{x}^{t} \mid \theta))$$

3. Optimization procedure:  $\theta$ 

$$\theta^* = \arg\min_{\theta} E(\theta \mid X)$$

정답을 가장 잘 맞추는 모델 파라미터를 찾는다.

#### 고려해야 할 point!

- 1. 어떤 모델을 써야할까
- 2. Task에 맞는 어떤 loss function 을 써야할 까
- 3. Parameter estimation하는 어떤 estimator 을 써야 할까



### **Maximum Likelihood Estimator**




### From Bayes Theorem

모델을 훈련한다. = Task를 이행하기 위해서, 훈련 데이터 셋에 가장 잘 맞도록 모델 파라미터를 설정

훈련 데이터 셋에 잘 맞는 파라미터

관측 훈련 데이터 셋이 주어졌을 때, 특정 파라미터의 그럴듯함.

**Posterior Probability of parameters** 






### Likelihood Function

$$\frac{P(\theta|X)}{\text{Unknown}} = \frac{P(X|\theta)p(\theta)}{P(X)} \propto \frac{P(X|\theta)}{\text{Likelihood function}}$$

다음과 같이 5개의 데이터를 얻었다고 가정하자.

$$x = \{1, 4, 5, 6, 9\}$$

이 때, 아래의 그림을 봤을 때 데이터 x는 주황색 곡선과 파란색 곡선 중 어떤 곡선으로부터 추출되었을 확률이 더 높을까?





# Log Likelihood Function

### Definition (Likelihood)

For  $X_1, \dots, X_n \stackrel{iid}{\sim} f_X(x; \theta)$ , where  $\theta$  denotes a parameter of interest. The likelihood function is

$$L(\theta; \mathbf{X}) = L(\theta; X_1, \cdots, X_n) = \prod_{i=1}^n f_X(X_i; \theta)$$

$$heta_{MLE} = rg \max_{ heta} P(X| heta)$$
 
$$= rg \max_{ heta} \prod_{i} \underbrace{P(x_i| heta)}_{0^\sim 1} heta$$
이 값으로 이루어진 확률값들의 곱  $o$ 0으로 가까워져 버린다.

$$egin{aligned} heta_{MLE} &= rg\max_{ heta} \log P(X| heta) \ &= rg\max_{ heta} \log \prod_{ ext{Likelihood function}} P(x_i| heta) \ &= rg\max_{ heta} \sum_{i} \log P(x_i| heta) \end{aligned}$$



### **Maximum Likelihood Estimator**

### • What is MLE?


#### Definition (Maximum likelihood estimator, MLE)

For  $X_1, \dots, X_n \stackrel{iid}{\sim} f_X(x; \theta)$ , the MLE of  $\theta$  is

$$\hat{\theta}_{MLE} = \operatorname*{argmax}_{\theta} L(\theta; \mathbf{x}).$$

which is equivalent to maximize the logarithm of  $L(\theta; \mathbf{x})$  which we call the log-likelihood

$$\ell(\theta; \mathbf{x}) = \log L(\theta; \mathbf{x}).$$





# Log Likelihood Function

Bernoulli distribution

$$\log L(p) = \sum_{i=1}^n (y_i \!\log p + (1-y_i) \!\log (1-p))$$

Multinomial distribution

$$\log L(p) = \sum_{i=1}^{n} \sum_{j=1}^{c} y_{ij} \log p_{j}$$

Binomial distribution

$$\log L(p) = \log \binom{n}{c} + \sum_{i=1}^{n} (y_i \log p + (1 - y_i) \log (1 - p))$$

Normal distribution

$$\log L(\mu) \approx -\frac{\sum_{i=1}^{n} (y_i - \mu)}{\sigma^2}$$



### MLE → Loss Function

"적합한 파라미터를 찾는" 같은 솔루션을 얻는 방법
Argmax → Argmin으로 문제를 바꿔, penalty의 성격을 띄게 된다.
결국, 손실함수를 최소화하는 parameter를 찾는 문제임

Loss function penalizes bad predictions.

### Regression

• Mean Squared Error

$$MSE = \frac{\sum_{i=1}^{n} (y_i - \hat{y}_i)^2}{n}$$

#### Others:

Mean absolute error and mean bias error

#### Classification

• Binary Cross Entropy

$$\textit{BCE} = -\frac{1}{N} \sum_{i=0}^{N} y_i \cdot \log(\hat{y_i}) + (1-y_i) \cdot \log(1-\hat{y_i})$$

Categorical Cross Entropy

$$\textit{CCE} = -\frac{1}{N} \sum_{i=0}^{N} \sum_{j=0}^{J} y_{j} \cdot \log(\hat{y_{j}}) + (1 - y_{j}) \cdot \log(1 - \hat{y_{j}})$$

#### Others:

Hinge loss / SVM loss.



### 3. Model Selection



### **Error**

- Error : deviation from an actual value by a prediction or expectation of that value
- Loss function: 모델의 학습 과정에서 최소화되어야 하는 함수로서 모델의 오류(Error)를 정량화하는 역할

### Error = Variance + Bias





Fig. 1 Graphical illustration of bias and variance.




# **Underfitting vs Overfitting**





# **Trade-off**




Bias / Variance dilemma : Geman et al. 1992



# **Model Selection**

Inductive Bias : Occam's Razor



#### If performances are similar,

Use the simpler one because

- Simpler to use (lower computational complexity)
- Easier to train (lower space complexity)
- Easier to explain (more interpretable)
- Generalizes better (lower variance)



### **Cross Validation**

To estimate generalization error, we need data unseen during training.

We split the data as

- Training set (50%)
- Validation set (25%)
- Test (publication) set (25%)

TRAIN

TEST

Train Model

TRAIN

TEST

Evaluate Model

Measure generalization accuracy by testing on data unused during training





### Regularization

### Penalize complex models

- E'=error on data +  $\lambda$ \*model complexity
- \* If  $\lambda$  increases, variance decreases, but bias increases

In regression...

Regularization (L2): 
$$E(\mathbf{w} \mid \mathcal{X}) = \frac{1}{2} \sum_{t=1}^{N} \left[ r^{t} - g(x^{t} \mid \mathbf{w}) \right]^{2} + \lambda \sum_{i} w_{i}^{2}$$



# 수고하셨습니다!

해당 세션자료는 KUBIG Github에서 보실 수 있습니다! 다음은 이번 주차 과제 설명이 있습니다!

