



## 시계열 분석 기법과 응용

### Week 2. ARMA 모형 2-2. 편자기상관함수


전치혁 교수  
(포항공과대학교 산업경영공학과)

# 편자기상관함수

## • 편자기상관 함수 (PACF)

- 정상적 시계열의 형태를 식별하는데 ACF외에 PACF의 정보를 활용함.  
ACF나 PACF를 통해 시계열 모형 식별 (시계열이 어떤 모형을 따르는지 모를 때)
- PACF란 시차가 k인 두 값들 간의 상관계수가 중간 시점들의 값들이 이미 설명한 이후 추가적인 영향만을 고려하기 위하여 고안된 것임. 따라서 다음과 같은 조건부 상관계수를 고려함

- ▶  $P(k) = \text{Corr}[Z_t, Z_{t-k} | \overbrace{Z_{t-1}, \dots, Z_{t-k+1}}^{\text{given 중간값}}], k = 0, 1, 2, \dots$ 
  - $P(1) = \rho(1)$ : 중간 값이 없으므로
  - $P(k)$  는 다음의 회귀모형의 계수  $\phi_{kk}$  와 동일하다  
 $- Z_t = \phi_{k1} Z_{t-1} + \phi_{k2} Z_{t-2} + \dots + \phi_{kk} Z_{t-k} + b_t$



# 편자기상관함수

- 아래 회귀모형에서  $P(k) = \phi_{kk}$ 
  - $Z_t = \phi_{k1}Z_{t-1} + \phi_{k2}Z_{t-2} + \cdots + \phi_{kk}Z_{t-k} + b_t$
  - 위의 식으로 부터  $k$ 개의 다음 식들이 유도된다.

$$\rho(1) = \phi_{k1} + \phi_{k2}\rho(1) + \cdots + \phi_{kk}\rho(k-1)$$

$$\rho(2) = \phi_{k1}\rho(1) + \phi_{k2} + \cdots + \phi_{kk}\rho(k-2)$$

...

$$\rho(k) = \phi_{k1}\rho(k-1) + \phi_{k2}\rho(k-2) + \cdots + \phi_{kk}$$

- 위의  <sup>$k$ 개</sup>연립방정식을 풀면  $\phi_{kk}$ 를 ACF로 부터 산출할 수 있다.  $\rightarrow$  소프트웨어 이용

# 편자기상관함수

(예 2-3) 시계열  $\{Z_t, t \geq 1\}$ 이 다음의 관계를 가질 때 이의 PACF를 구하라.

$$Z_t = a_t - \theta a_{t-1}$$

(풀이)

1)  $P(1)=\rho(1)$  인데 (예2-2)에서  $\rho(1) = \frac{-\theta}{1+\theta^2}$  이다.

2)  $P(2) = \phi_{22}$  를 구하기 위해 연립방정식을 기술하면

$$\begin{cases} \rho(1) = \phi_{21} + \phi_{22}\rho(1) \\ \rho(2) = \phi_{21}\rho(1) + \phi_{22} \end{cases}$$

$\nwarrow \phi_{22}$  찾기

$\rho(2) = 0$ 을 이용하면 다음과 같다.

$$P(2) = \phi_{22} = \frac{-\rho^2(1)}{1-\rho^2(1)} = \frac{-\theta^2}{1+\theta^2+\theta^4}$$

3) 위와 같은 방법으로  $P(k), k = 3, 4, \dots$  을 구할 수 있다.

$$\begin{aligned} \rightarrow \rho(1) &= \phi_{21} + \phi_{22}\rho(1) = \frac{-\theta}{1+\theta^2} \\ \therefore \phi_{21} + \phi_{22} \cdot \frac{-\theta}{1+\theta^2} &= \frac{-\theta}{1+\theta^2} \\ (1-\phi_{22}) \cdot \frac{\theta}{1+\theta^2} &= -\phi_{21} \\ \rho(2) &= (1-\phi_{22}) \left( \frac{-\theta}{1+\theta^2} \right)^2 + \phi_{22} = 0 \\ A - \phi_{22}A + \phi_{22} &= 0 \quad (1-A)\phi_{22} = -A \\ \phi_{22} &= \frac{-A}{1-A} = - \frac{\frac{\theta^2}{\theta^4+\theta^2+1}}{\frac{\theta^4+\theta^2+1}{\theta^4+\theta^2+1}} = - \frac{\theta^2}{\theta^4+\theta^2+1} \end{aligned}$$

# 시계열 표현방식

각각 정한정 존재

- 자기회귀 (autoregressive; AR) 표현방식

자기변수만 가지고 표현

- 시점 $t$ 의 값 ( $Z_t$ )을 과거시점의 값들을 이용한 회귀식으로 표현

- $Z_t = \pi_1 Z_{t-1} + \pi_2 Z_{t-2} + \dots + a_t$

- 여기서  $\pi_1, \pi_2$  등은 상수이며  $a_t$ 는 백색잡음 (white noise)

- 자기회귀 과정 (autoregressive process)라고도 함

- 이동평균 (moving average; MA) 표현방식

- 시점 $t$ 의 값 ( $Z_t$ )을 현재와 과거시점의 백색잡음으로 표현

- $Z_t = a_t - \psi_1 a_{t-1} - \psi_2 a_{t-2} - \dots$

- 여기서  $\psi_1, \psi_2$  등은 상수

- 이동평균 과정 (moving average process)라고도 함

# 시계열 표현방식

↖ 일반화를 위한 표현

- 후향 연산자 (backward shift operator/ backshift operator) 사용 →  $t$ 시점 기준으로 표현

$$- Z_{t-1} = \textcircled{B} Z_t$$

$$- Z_{t-2} = \underline{B Z_{t-1}} = B^{\textcircled{2}} Z_t$$

$$- \underline{Z_{t-k}} = B^{\textcircled{k}} Z_t, k = 1, 2, \dots$$

## AR과정의 표현

$$\begin{aligned} Z_t &= \pi_1 Z_{t-1} + \pi_2 Z_{t-2} + \dots + a_t \Rightarrow Z_t = (\pi_1 B + \pi_2 B^2 + \dots) \textcircled{Z_t} + a_t \\ &\Rightarrow (1 - \pi_1 B - \pi_2 B^2 - \dots) Z_t = a_t \\ &\Rightarrow \underline{Z_t = (1 - \pi_1 B - \pi_2 B^2 - \dots)^{-1} a_t} \end{aligned}$$

## MA과정의 표현

$$\begin{aligned} Z_t &= a_t - \psi_1 \underbrace{a_{t-1}}_{\text{패}} - \psi_2 \underbrace{a_{t-2}}_{\text{패}} - \dots \Rightarrow Z_t = (1 - \psi_1 B - \psi_2 B^2 - \dots) a_t \\ &\Rightarrow (1 - \psi_1 B - \psi_2 B^2 - \dots)^{-1} Z_t = a_t \end{aligned}$$

# 시계열 표현방식

(예 2-4) 다음의 시계열을 AR표현방식과 MA표현방식으로 나타내라.

$$Z_t = a_t - \frac{0.5a_{t-1}}{0.5B a_t} + \frac{0.3a_{t-2}}{0.3B^2 a_t}$$

(풀이)

- 이미 MA방식으로 표현되어있다. 즉,  
 $\psi_1 = 0.5, \psi_2 = -0.3, \psi_k = 0, k = 3, 4, \dots$

- AR방식으로 표현하기 위해 후방연산자를 사용하면

$$Z_t = (1 - 0.5B + 0.3B^2 - \dots)a_t \Rightarrow (1 - 0.5B + 0.3B^2 - \dots)^{-1} Z_t = (a_t)$$

$$\Rightarrow (1 + 0.5B - 0.05B^2 - 0.175B^3 - \dots)Z_t = a_t$$

$$\Rightarrow Z_t = -0.5Z_{t-1} + 0.05Z_{t-2} + 0.175Z_{t-3} + \dots + a_t$$

따라서

$$\pi_1 = -0.5, \pi_2 = 0.05, \pi_3 = 0.175, \dots$$



## 시계열 분석 기법과 응용

Week 2. ARMA 모형

2-1. 자기상관함수

전치혁 교수  
(포항공과대학교 산업경영공학과)




# 정상적 시계열

- 정상적 시계열 (Stationary Time Series)

- 실제 시계열은 추세, 계절성을 포함하는 비정상적 (non-stationary)인 것이 많으나 우선 정상적 시계열의 성질을 알아본다.
- 비정상적 시계열은 적절한 변환을 통하여 정상적 시계열로 바꿀 수 있다.

- 강 정상성 (Strong Stationarity)

- 시계열  $\{Z_t, t \geq 1\}$ 에 대해  $(Z_1, \dots, Z_m)$ 과  $(Z_{1+k}, \dots, Z_{m+k})$ 이 동일한 결합확률분포를 가질 때 강 정상성을 갖는 시계열이라 함
- 기대치가 시간에 따라 일정
- 분산이 시간에 따라 일정
- 자기공분산 또는 자기상관계수가 시간 간격 (time lag)에만 의존



- 약 정상성 (Weak Stationarity):

자기공분산은  
시간 간격에만  
의존

- 시계열  $\{Z_t, t \geq 1\}$ 에 대해 기대치가 시간에 따라 일정하고 임의의 두 시점 자기공분산이 시간 간격에만 의존하고 **유한**할 때 약 정상성을 갖는 시계열이라 함
- 강 정상성이 성립하면 약 정상성이 성립; 역은 성립하지 않음
- 결합확률분포가 다변량정규분포를 따를 때 강 정상성과 약 정상성은 **일치**
- 시계열분석에서는 주로 약 정상성을 가정함; 본 강의에서도 약 정상성을 가정하여 이론 전개

# 자기상관함수

시간에 따른 변수의 관계

## • 자기 공분산 (autocovariance)

- 시계열의 시간에 따른 연관 패턴을 자기공분산으로 요약
- 시차  $k$ 의 자기공분산

$$\checkmark \gamma(k) = Cov[Z_t, Z_{t-k}] = E[(Z_t - \mu_Z)(Z_{t-k} - \mu_Z)] \quad (\text{약 정상성 가정})$$

$\xrightarrow{\text{k만큼 떨어진 시점}}$        $\xrightarrow{\text{avg 공분산 정의}}$

$$\text{시차 } 0 \therefore \text{분산과 동일} = E[Z_t Z_{t-k}] \quad (\mu_Z = 0 \text{ 가정})$$

$\xrightarrow{\text{약정상성 가정에 의해 평균동일}}$

$$\checkmark \gamma(0) = Var[Z_t]$$

$$\checkmark \gamma(k) = \gamma(-k) \quad \text{공분산은 0에 대해 대칭}$$

✓  $\gamma(k)$  를  $k$ 의 함수( $k = 0, 1, 2, \dots$ )로 볼 때, 자기공분산 함수 (autocovariance function)라 함

	t-4	t-3	t-2	t-1	t	
	$Z_{t-4}$	$Z_{t-3}$	$Z_{t-2}$	$Z_{t-1}$	$Z_t$	

$\underbrace{\hspace{10em}}_{\gamma(3)} \quad \underbrace{\hspace{5em}}_{\gamma(2)} \quad \underbrace{\hspace{5em}}_{\gamma(1)} \quad \underbrace{\hspace{5em}}_{\gamma(0)}$

$\gamma(2)$        $\gamma(1)$        $\gamma(0)$

\*  $k$ 가 작을수록 밀접한 시차만큼만 관련될 수 있음

# 자기상관함수

- 자기상관 함수 (autocorrelation function; ACF)

시차 k의 자기상관계수:

$$\rho(k) = \text{Corr}[Z_t, Z_{t-k}] = \frac{\text{Cov}[Z_t, Z_{t-k}]}{\text{Var}[Z_t]} = \frac{\gamma(k)}{\gamma(0)}$$


$\uparrow$  점의 상관관계:  $\sqrt{\text{Var}(Z_t)} \sqrt{\text{Var}(Z_{t-k})}$   
공분산

✓  $\rho(0) = 1$

✓  $\rho(k) = \rho(-k)$  : 대칭


✓  $\rho(k)$  를 k의 함수 ( $k = 0, 1, 2, \dots$ )로 볼 때, 자기상관 함수 (autocorrelation function; ACF)라 함

✓ 비교적 단순한 형태의 정상적 시계열 모델을 주로 다루며 ACF로 모델을 식별함




# 자기상관함수

무정성



$\phi > 1$



## 자기상관 함수 산출 예

(예 2-1) 시계열  $\{Z_t, t \geq 1\}$ 이 다음의 관계를 가질 때 이의 ACF를 구하라.

$$Z_t = \phi Z_{t-1} + a_t$$

여기서  $a_t$ 는 평균 0, 분산  $\sigma_a^2$ 를 갖는 백색잡음(white noise)으로 불리는 오차항임.

이 시계열이 정상적이라면  $-1 < \phi < 1$ 이어야 한다.

(풀이)

- ①  $k=1$ 에 대한 자기공분산을 구하기 위해 양변에  $Z_{t-1}$ 을 곱하고 기대치를 취하면

$$E[Z_t Z_{t-1}] = \phi E[Z_{t-1}^2] + E[a_t Z_{t-1}] \Rightarrow \gamma(1) = \phi \gamma(0) \quad \text{양변을 } \gamma(0) \text{로 나누면, } \rho(1) = \phi$$

- ①  $k=2$ 에 대한 자기공분산을 구하기 위해 양변에  $Z_{t-2}$ 을 곱하고 기대치를 취하면  $E[Z_t Z_{t-2}] = \phi E[Z_{t-1} Z_{t-2}] + E[a_t Z_{t-2}] \Rightarrow \gamma(2) = \phi \gamma(1)$  양변을  $\gamma(0)$ 로 나누면,  $\rho(2) = \phi \rho(1) = \phi^2$

- ② 위와 같은 방식을 적용하면 ACF는 다음과 같다.  $\rho(k) = \phi \rho(k-1) = \phi^k, k = 1, 2, \dots$

참고로  $Z_t$ 의 분산은 다음과 같다. 양변에 분산을 취하면,

$$\gamma(0) = \text{Var}[Z_t] = \phi^2 \text{Var}[Z_{t-1}] + \text{Var}[a_t] + 2\text{Cov}[Z_{t-1}, a_t] \Rightarrow \gamma(0) = \phi^2 \gamma(0) + \sigma_a^2 \Rightarrow \gamma(0) = \frac{\sigma_a^2}{1-\phi^2}$$

$$\hookrightarrow \text{Var}(Z_t) = E(Z_t^2) - E(Z_t)^2 = E(\phi^2 Z_{t-1}^2 + 2\phi Z_{t-1} a_t + a_t^2) = \phi^2 E(Z_{t-1}^2) + 2\phi E(Z_{t-1} a_t) + E(a_t^2) = \phi^2 \gamma(0) + \sigma_a^2 = \gamma(0) \quad \rightarrow \quad \gamma(0) = \frac{\sigma_a^2}{1-\phi^2}$$

이때의 시계열 값  
= (t-1)의 시계열 값  $\times \phi + \text{noise}$

다른 것들과 독립

평균 0으로 가정

$$\begin{aligned} \rightarrow \gamma(1) &= E(Z_t Z_{t-1}) \\ &= \phi E(Z_{t-1}^2) + E(a_t Z_{t-1}) \\ &= \phi E(Z_{t-1}^2) = \phi \gamma(0) \\ &\quad \text{by independence} \quad E(a_t Z_{t-1}) = 0 \text{ 독립} \\ &\quad = E(Z_t^2) - \text{Var}(Z_t) = \gamma(0) \end{aligned}$$

# 자기상관함수

(예 2-2) 시계열  $\{Z_t, t \geq 1\}$ 이 다음의 관계를 가질 때 이의 ACF를 구하라.

$$Z_t = a_t - \theta a_{t-1}$$

←  $t$ 시점 시계열 값 = 이전 시점의 백분율  $\theta$ 의  $a$  + noise

(풀이)

① 우선 분산은 다음과 같이 산출된다.

$$\gamma(0) = E[Z_t^2] = E[(a_t - \theta a_{t-1})^2] = (1 + \theta^2)\sigma_a^2 \quad * \text{백분율은 2로 독립!}$$

②  $k=1$ 에 대한 자기공분산을 구하면

$$\gamma(1) = E[Z_t Z_{t-1}] = E[(a_t - \theta a_{t-1})(a_{t-1} - \theta a_{t-2})] = E[-\theta a_{t-1}^2] = \underline{-\theta \sigma_a^2}$$

따라서,  $\boxed{\rho(1) = \frac{\gamma(1)}{\gamma(0)} = \frac{-\theta}{1+\theta^2}}$

③  $k=2$ 에 대한 자기공분산을 구하면

$$\gamma(2) = E[Z_t Z_{t-2}] = E[(a_t + \theta a_{t-1})(a_{t-2} + \theta a_{t-3})] = 0$$

따라서 ACF는 다음과 같다.

$$\rho(k) = \begin{cases} \frac{-\theta}{1+\theta^2} & k = 1 \\ 0 & k = 2, 3, \dots \end{cases}$$



## 시계열 분석 기법과 응용

### Week 2. ARMA 모형 2-3. AR모형과 MA모형

전치혁 교수  
(포항공과대학교 산업경영공학과)

# ARMA 모형

- AR 모형

- AR 표현방식이며 유한 시차로 구성
- AR(1): 시차 1 변수 포함

$$Z_t = \phi_1 Z_{t-1} + a_t$$

- MA 모형

- MA 표현방식이며 유한 시차로 구성
- MA(1): 시차 1 백색잡음 포함

$$Z_t = a_t - \theta a_{t-1}$$

- ARMA 모형

- AR방식과 MA방식이 결합된 형태
- ARMA(1,1): 시차1의 변수와 시차1의 백색잡음 포함

$$Z_t = \phi_1 Z_{t-1} + a_t - \theta a_{t-1}$$

# AR 모형

- AR(1) 모형: 가장 단순한 상태

- $Z_t = \phi_1 Z_{t-1} + a_t$
- $a_t$ 는 평균 0, 분산  $\sigma_a^2$ 의 독립인 백색잡음 (white noise)이라 부르는 오차항
- 시점 t의 값은 시점 t-1의 값과 오차항으로 생성된다
- 상수항을 포함시킬 수 있으나 통상  $Z_t$ 의 평균을 0으로 가정하여 생략함
- 정상성을 갖기 위해 모수  $\phi_1$ 에 대한 조건 필요:  $-1 < \phi_1 < 1$   
이 조건 만족  $X \rightarrow$  증가 이 감소 추세도 나타나게 됨

- AR(2) 모형: 시차 2변수까지 포함

- $Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + a_t$
- 정상성 조건:  $-1 < \phi_2 < 1, \phi_1 + \phi_2 < 1, \phi_2 - \phi_1 < 1$

- AR(p) 모형: 시차 p의 변수까지 포함


- $Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + \dots + \phi_p Z_{t-p} + a_t$
- 정상성을 갖기 위해 모수  $\phi_1, \dots, \phi_p$ 에 대한 조건 필요: 다소 복잡  
소프트웨어 이용



# AR 모형


- AR(1) 모형의 ACF

- $Z_t = \phi_1 Z_{t-1} + a_t \quad -1 < \phi_1 < 1$
- $Var[Z_t] = \gamma(0) = \frac{\sigma_a^2}{1-\phi_1^2}$  by ppt 2-1 p.5
- $\gamma(k) = \phi_1^k \gamma(0), k = 0, 1, 2, \dots$
- $\rho(k) = \frac{\gamma(k)}{\gamma(0)} = \phi_1^k, k = 0, 1, 2, \dots$   
지수적으로 감소하는 패턴 ( $-1 < \phi_1 < 1$  이므로)



- AR(1) 모형의 PACF

- $\underline{P(1) = \rho(1) = \phi_1}$
- $\underline{P(k) = 0, k = 2, 3, \dots}$ : 시차 1 이후  
절단 패턴



# AR 모형

## • AR(2) 모형의 ACF

- 양변에 분산을 취하면

$$(1 - \phi_1^2 - \phi_2^2)\gamma(0) = \sigma_a^2 + 2\phi_1\phi_2\gamma(1)$$

- 양변에  $Z_{t-1}$  곱하고 기대치 취하면

$$\gamma(1) = \phi_1\gamma(0) + \phi_2\gamma(1) \Rightarrow \gamma(1) = \frac{\phi_1\gamma(0)}{1-\phi_2}$$

- 분산은 다음과 같다


$$\gamma(0) = \frac{1-\phi_2}{(1+\phi_2)(1+\phi_1-\phi_2)(1-\phi_1-\phi_2)}\sigma_a^2$$

- AR(2)의 ACF

$$\rho(1) = \frac{\phi_1}{1-\phi_2}, \rho(k) = \phi_1\rho(k-1) + \phi_2\rho(k-2), k = 2, 3, \dots$$

(지수적으로 감소)

$$Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + a_t$$



$$\phi_1 = 0.7, \phi_2 = -0.1$$

# AR 모형

- AR(2) 모형의 PACF

$$Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + a_t$$

- $- P(1) = \rho(1) = \frac{\phi_1}{1 - \phi_2}$


- $- P(2) = \phi_2$

- $- P(k) = 0, k = 3, 4, \dots$  (시차2이후 절단)

$P(3)$ 는 다음 회귀모형에서  $\phi_{33}$  값:

- ✓  $Z_t = \phi_{31} Z_{t-1} + \phi_{32} Z_{t-2} + \phi_{33} Z_{t-3} + a_t$

- ✓ AR(2) 모형과 비교하면  $P(3) = \phi_{33} = 0$



# AR 모형

ACF : 지수적 감소  
PACF : p 이후 절단

- AR(p) 모형

$$Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + \cdots + \phi_p Z_{t-p} + a_t$$
$$\Rightarrow (1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_p B^p) Z_t = a_t \Rightarrow \underline{\Phi_p(B) Z_t = a_t}$$

ACF

Yule-Walker 방정식을 풀어 산출 가능

$$\rho(k) = \phi_1 \rho(k-1) + \phi_2 \rho(k-2) + \cdots + \phi_p \rho(k-p), k = 1, 2, \dots$$

정상성 조건

다항식  $\Phi_p(x) = 0$ 의 p개 근의 크기(modulus)가 1보다 커야한다. 이론적 조건

→ 확장연산자로 표현한 다항식

# MA 모형

→ 그 자체로 정상성을 가지나  
가역성 조건 필요

- MA(1) 모형: 시차1의 백색잡음 포함

$$Z_t = a_t - \theta_1 a_{t-1}$$

- $a_t$ 는 평균 0, 분산  $\sigma_a^2$ 의 독립인 백색잡음 (white noise)이라 부르는 오차항
- 시점 t의 값은 시점 t와 시점 t-1의 오차항으로 생성된다
- 정상성을 갖는다.
- AR형태로 표현하기 위해 모수  $\theta_1$ 에 대한 가역성 (invertibility) 조건 필요:  $-1 < \theta_1 < 1$   
↳ 역수 가능해야 하므로

- MA(2) 모형: 시차 2의 백색잡음까지 포함

- $Z_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2}$
- 가역성 조건:  $-1 < \theta_2 < 1, \theta_1 + \theta_2 < 1, \theta_2 - \theta_1 < 1$


- MA(q) 모형: 시차 q의 백색잡음까지 포함

- $Z_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \dots - \theta_q a_{t-q}$
- 가역성을 갖기 위해 모수  $\theta_1, \dots, \theta_q$ 에 대한 조건 필요: 다소 복잡

# MA 모형

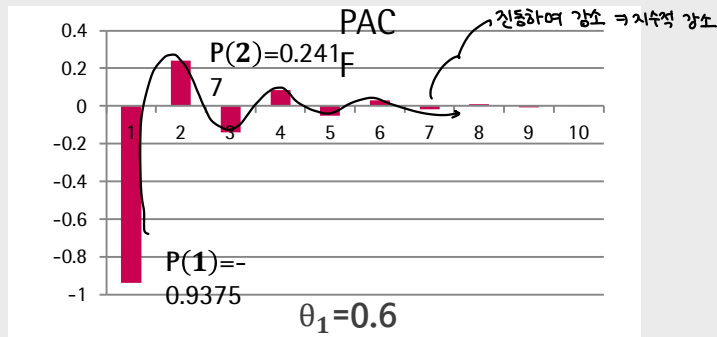
## • MA(1) 모형의 ACF

- $Z_t = a_t - \theta_1 a_{t-1} \quad -1 < \theta_1 < 1$
- $Var[Z_t] = \gamma(0) = (1 + \theta_1^2) \sigma_a^2$
- $\rho(k) = \begin{cases} \frac{-\theta_1}{1-\theta_1^2}, & k = 1 \\ 0, & k \geq 2 \end{cases}$  : 시차 1 이후 절단 패턴



## • MA(1) 모형의 PACF

- $P(1) = \rho(1) = \frac{-\theta_1}{1-\theta_1^2}$
- $P(2) = \frac{\rho(2) - \rho^2(1)}{1 - \rho^2(1)} = \frac{-\theta_1^2(1-\theta_1^2)}{1-\theta_1^6}$
- $P(k) = \frac{-\theta_1^k(1-\theta_1^2)}{1-\theta_1^{2(k+1)}}, k = 1, 2, \dots$  : 지수적으로 감소 패턴



# MA 모형

- MA(2) 모형의 ACF 와 PACF

$$Z_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2}$$

분산

$$\gamma(0) = (1 + \theta_1^2 + \theta_2^2)\sigma_a^2$$



ACF

$$\rho(1) = \frac{-\theta_1 + \theta_1\theta_2}{1 + \theta_1^2 + \theta_2^2}, \rho(2) = \frac{-\theta_2}{1 + \theta_1^2 + \theta_2^2}, \rho(k) = 0, k = 3, 4, \dots$$

(시차 2 이후 절단 형태)

PACF

지수적으로 감소하는 형태



# MA 모형

\* ARMA

→ ACF, PACF 모두 이용해  
식별해야 함.

ARMA(p, q)

p ≥ q → ACF는 AR(p)과

유사한 패턴

ACF : q이후 절단  
PACF : 지수적 감소

## • MA(q) 모형

$$Z_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \dots - \theta_q a_{t-q}$$
$$\Rightarrow Z_t = (1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q) a_t \Rightarrow Z_t = \Theta_q(B) a_t$$

분산

$$\gamma(0) = (1 + \theta_1^2 + \theta_2^2 + \dots + \theta_q^2) \sigma_a^2 = E(Z_t^2)$$

가역성 조건

다항식  $\Theta_q(x) = 0$ 의 q개 근의 크기(modulus)가 1보다 커야 한다.

ACF

$$\rho(k) = \frac{-\theta_k + \theta_{k+1}\theta_1 + \dots + \theta_q\theta_{q-k}}{1 + \theta_1^2 + \theta_2^2 + \dots + \theta_q^2}, k = 1, 2, \dots, q \quad \rho(k) = 0, k \geq q + 1 \quad (\text{절단 패턴})$$

PACF

지수적으로 감소





## 시계열 분석 기법과 응용

### Week 2. ARMA 모형 2-4. ARMA모형

전치혁 교수  
(포항공과대학교 산업경영공학과)

# ARMA 모형

~ ARMA의 가장 단순한 형태

- ARMA(1,1) 모형: AR(1)과 MA(1)의 복합 형태

- $\overbrace{Z_t - \phi_1 Z_{t-1}}^{\text{AR(1)형}} = \overbrace{a_t - \theta_1 a_{t-1}}^{\text{MA(1)형}}$
- 시점 t의 값은 시점 t-1의 값, 그리고 시점 t와 t-1의 오차항으로 생성된다
- 정상성을 갖기 위해 모수  $\phi_1$ 에 대한 조건 필요:  $-1 < \phi_1 < 1$
- 가역성을 위해 모수  $\theta_1$ 에 대한 조건 필요:  $-1 < \theta_1 < 1$

- ARMA(p,q) 모형: 시차 p까지 변수와 시차 q까지 오차항 포함

- $\overbrace{Z_t - \phi_1 Z_{t-1} - \phi_2 Z_{t-2} - \dots - \phi_p Z_{t-p}}^{\text{AR(p)형}} = \overbrace{a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \dots - \theta_q a_{t-q}}^{\text{MA(q)형}}$   
 $\Rightarrow \Phi_p(B)Z_t = \Theta_q(B)a_t$  (항변수 생략)
- 정상성을 갖기 위해 모수  $\phi_1, \dots, \phi_p$ 에 대한 조건 필요:  
다항식  $\Phi_p(x) = 0$ 의 p개 근의 크기(modulus)가 1보다 커야한다
- 가역성을 갖기 위해 모수  $\theta_1, \dots, \theta_q$ 에 대한 조건 필요:  
다항식  $\Theta_q(x) = 0$ 의 q개 근의 크기(modulus)가 1보다 커야한다.

# ARMA 모형

## • ARMA(1,1) 모형의 ACF

$$Z_t = \phi_1 Z_{t-1} + a_t - \theta_1 a_{t-1} \quad -1 < \phi_1 < 1; -1 < \theta_1 < 1$$

$$\rho(1) = \frac{(\phi_1 - \theta_1)(1 - \phi_1 \theta_1)}{1 + \theta_1^2 - 2\phi_1 \theta_1}$$

$$\rho(k) = \phi_1^{k-1} \rho(1), k = 2, 3, \dots$$

지수적으로 감소하는 패턴

## • ARMA(1,1) 모형의 PACF


$$P(1) = \rho(1) = \frac{(\phi_1 - \theta_1)(1 - \phi_1 \theta_1)}{1 + \theta_1^2 - 2\phi_1 \theta_1}$$

$$P(2) = \frac{\rho(2) - \rho^2(1)}{1 - \rho^2(1)} = \frac{\rho(1)(\phi_1 - \rho(1))}{1 - \rho^2(1)}$$


$$P(3) = \frac{\rho^3(1) - 2\rho(1)\rho(2) + \rho(1)\rho^2(2)}{1 - 2\rho^2(1) + 2\rho^2(1)\rho(2) - \rho^2(2)}$$

지수적으로 감소하는 패턴 (정안형태 X)

ACF



PACF



$\phi_1=0.7, \theta_1=0.5$

# ARMA 모형

- ARMA(p,q) 모형

$$\frac{Z_t - \phi_1 Z_{t-1} - \phi_2 Z_{t-2} - \cdots - \phi_p Z_{t-p}}{\Rightarrow \Phi_p(B)Z_t} = \frac{a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \cdots - \theta_q a_{t-q}}{\Theta_q(B)a_t}$$

실제 시계열 데이터에 적용시  
AR, MA, ARMA 중 어떤 모형인지, p, q가 어떤 시차인지  
식별하기 위해 사용

## ACF

↳ Yule-Walker 방정식 풀어서 구함

- $\rho(k) = \phi_1 \rho(k-1) + \cdots + \phi_p \rho(k-p), k \geq \max(p, q+1)$

★

- $p \geq q+1$  일 때, ACF는 AR(p) 모형과 유사하게 0으로 떨어진다.

- $p \leq q$  일 때, 처음  $q-p$  값은 별개의 값을 갖고 이 이후 AR(p) 모형과 유사하게 0으로 떨어진다.

## PACF

★

- $p \geq q+1$  일 때, PACF는 처음  $p-q$  값은 별개의 값을 갖고 이 이후 MA(q) 모형과 유사하게 0으로 떨어진다.

- $p \leq q$  일 때, 처음부터 MA(q) 모형과 유사하게 0으로 떨어진다.

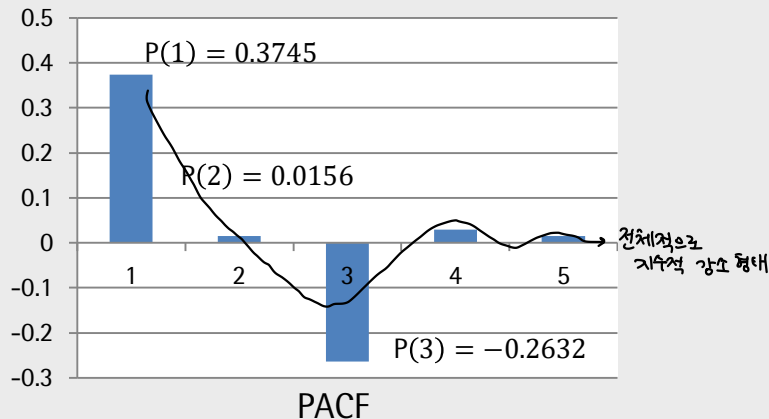

# ARMA 모형

## ARMA(1,3) 모형 vs ARMA(3,1) 모형

- ARMA(1,3) 모형 ( $p < q$ )

$$Z_t - 0.7Z_{t-1} = a_t - 0.7a_{t-1} - 0.2a_{t-2} - 0.5a_{t-3}$$

q-p=2이므로 ACF의 처음 2개는 별개 값이고 그 이후 지수적으로 감소;  
PACF는 처음부터 지수적으로 감소



# ARMA 모형


## ARMA(3,1) 모형 vs ARMA(1,3) 모형

- ARMA(3,1) 모형  $p > q$


$$Z_t - 0.7Z_{t-1} + 0.1Z_{t-3} = a_t - 0.5a_{t-1}$$

$$\rho(k) = 0.7\rho(k-1) - 0.2\rho(k-3), \quad k = 2, 3, 4, \dots$$

p-q=2이므로 ACF의 처음부터  
지수적으로 감소; PACF는 처음  
2개는 별개 값이며 그 이후 지수  
적으로 감소



ACF



PACF

Q: 그래프 어떻게 다른가..? : 어떤 점 : 식별에 이용 가능

# ARMA 모형

## ARMA모형의 이론적 ACF와 PACF의 패턴

모형	ACF	PACF
AR(p)	지수적으로 감소	시차 p 이후 절단
MA(q)	시차 q 이후 절단	지수적으로 감소
ARMA(p, q)	시차 (q-p) 이후 지수적 감소	시차 (p-q) 이후 지수적 감소