

# WEEK2

- 정상적 ARMA 모형: AR모형, MA모형, ARMA모형
- 비정상적 모형: ARIMA 모형, 계절성 ARIMA 모형
- 다변량 시계열: VAR

## 1. 자기상관함수

- 시계열 자료의 큰 특징 = 시간의 흐름에 따라 독립적이지 않다는 것  $\Rightarrow$  자기상관관계를 가짐

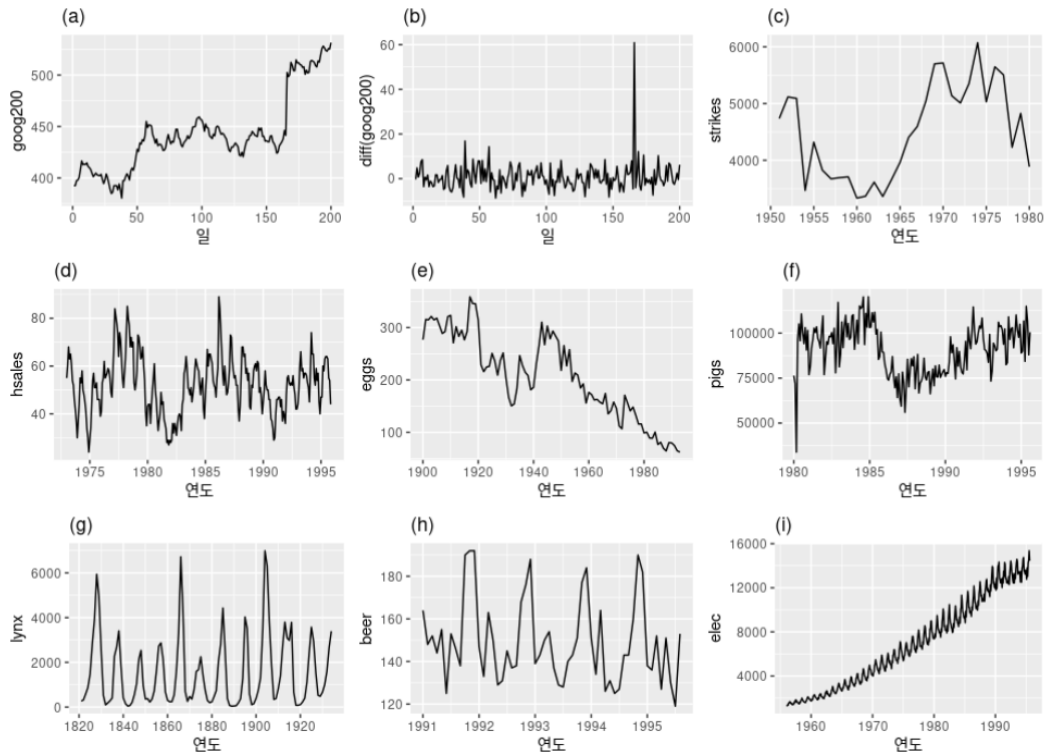
- 따라서, 시간에 따른 상관 정도를 나타내야 함  $\Rightarrow$  '자기상관함수(AutoCovariance Function)'

- 정상성이란?
  - 1) 일정한 평균
    - 모든 시점에 대해 평균이 일정해야 함: if not, 차분을 통해 정상화 필요
    - $\Rightarrow$  차분 = (현 시점의 자료 값) - (전 시점의 자료 값)
  - 2) 일정한 분산
    - 모든 시점에 대해 분산이 동일해야 함: if not, 변환을 통해 정상화 필요
    - $\Rightarrow$  변환: 자료 값에 지수 혹은 로그를 취함  $\rightarrow$  시간에 따라 변하는 분산 크기 안정화
  - 3) 시차에만 의존하는 공분산
    - 시차 의존, 시점 의존 X
    - t는 시점, s는 시차라고 했을 때, 't시점과 t+s시점의 공분산'과 't시점과 t-s시점의 공분산'은 서로 같음
    - 다만, 시차에 따라 공분산 값이 다를 수는 있음

+ 추세나 계절성 등의 시계열 자료는 정상성을 띠지 않는다고 보아야 함

But, 주기성 행동을 가지지만(추세나 계절성은 없는)시계열은 정상성을 나타내는 시계열임

(ex) 정상성을 띠는 시계열 찾기



- 이 중, (b),(g)만이 정상성을 나타내는 시계열 후보임. 특히, (g)의 경우는 일정한 주기를 띠는다고 착각할 수 있지만, 해당 주기는 불규칙적임( → (g): 캐나다 북서부의 맥킨지 강 지역에서 연간 포획된 스라소니의 전체 수). 먹이를 구하기 힘들만큼 살쾡이 개체 수가 너무 많이 늘어나 번식을 멈춰서, 개체수가 작은 숫자로 줄어들고, 그 다음 먹이를 구할 수 있게 되어 개체수가 다시 늘어나는 식임. 장기적으로 볼 때, 이러한 주기의 시작이나 끝은 예측할 수 없으므로 정상성을 띠는다고 보아야 함

- 자기 공분산: 시계열의 시간에 따른 연관 패턴을 나타냄  
- 시차 k의 자기공분산

$$\gamma(k) = \text{Cov}[Z_t, Z_{t-k}] = E[(Z_t - \mu_Z)(Z_{t-k} - \mu_Z)] \quad (\text{약 정상성 가정})$$

$$= E[Z_t Z_{t-k}] \quad (\mu_Z = 0 \text{ 가정})$$

$$\gamma(0) = \text{Var}[Z_t]$$

$$\gamma(k) = \gamma(-k)$$

$\gamma(k)$ 를 k의 함수 ( $k = 0, 1, 2, \dots$ )로 볼 때, 자기공분산 함수 (autocovariance function)라 함

- 자기상관 함수(ACF)  
- 일반적으로 ACF 값은 시차와 크기와 반비례

- 비교적 단순한 형태의 정상적 시계열 모델을 주로 다루며, ACF로 모델을 식별할 수 있음

시차 k의 자기상관계수:

$$\rho(k) = \text{Corr}[Z_t, Z_{t-k}] = \frac{\text{Cov}[Z_t, Z_{t-k}]}{\text{Var}[Z_t]} = \frac{\gamma(k)}{\gamma(0)}$$

$$\checkmark \quad \rho(0) = 1$$

$$\checkmark \quad \rho(k) = \rho(-k)$$

공분산을 분산으로 나눈 형태

## 2. 편자기상관함수

- 정상적 시계열의 형태를 식별하기 위해 ACF외에 PACF의 정보를 활용함
- PACF는 시차 k 사이의 값들은 conditional이라고 가정. 따라서 조건부 상관계수를 고려함
- P(k)는 다음의 회귀모형에서의 kk번째 회귀계수와 같다고 알려져 있음
- ACF와의 차이점은, 다른 시점의 확률변수 영향력은 통제하고 '상관관계만' 보여준다는 것
- (ex) 교회수와 범죄발생률이 비례한다고 가정 → 교회가 많다는 것은 인구수 또한 많은 것 → '인구' 요소를 제외하고, 오로지 교회와 범죄발생률만을 놓고 상관계수를 분석

$$Z_t = \phi_{k1}Z_{t-1} + \phi_{k2}Z_{t-2} + \cdots + \phi_{kk}Z_{t-k} + b_t$$

- 시계열 표현방식
  - 자기회귀(AR) 방식: 시점 t의 값을 과거시점의 값들을 이용한 회귀식으로 표현. 과거시점의 값들과 백색잡음( $a_t$ )이 포함된 식임
  - 이동평균(MA) 방식: 시점 t의 값을 현재와 과거시점의 백색잡음만으로 표현
- 후향연산자 표현

$$\begin{aligned}
- Z_{t-1} &= BZ_t \\
- Z_{t-2} &= BZ_{t-1} = B^2Z_t \\
- Z_{t-k} &= B^kZ_t, k = 1, 2, \dots
\end{aligned}$$

-B가 곱해져 있는 만큼, 데이터를 한 시점 뒤로 옮기는 효과를 나타냄

### AR과정의 표현

$$\begin{aligned}
Z_t &= \pi_1 Z_{t-1} + \pi_2 Z_{t-2} + \dots + a_t \Rightarrow Z_t = (\pi_1 B + \pi_2 B^2 + \dots) Z_t + a_t \\
&\Rightarrow (1 - \pi_1 B - \pi_2 B^2 - \dots) Z_t = a_t \\
&\Rightarrow Z_t = (1 - \pi_1 B - \pi_2 B^2 - \dots)^{-1} a_t
\end{aligned}$$

### MA과정의 표현

$$\begin{aligned}
Z_t &= a_t - \psi_1 a_{t-1} - \psi_2 a_{t-2} - \dots \Rightarrow Z_t = (1 - \psi_1 B - \psi_2 B^2 - \dots) a_t \\
&\Rightarrow (1 - \psi_1 B - \psi_2 B^2 - \dots)^{-1} Z_t = a_t
\end{aligned}$$

$\underbrace{-\psi_1 a_{t-1}}_{B a_t} \quad \underbrace{-\psi_2 a_{t-2}}_{B^2 a_t}$

(예 2-4) 다음의 시계열을 AR표현방식과 MA표현방식으로 나타내라.

$$Z_t = a_t - 0.5a_{t-1} + 0.3a_{t-2}$$

(풀이)

■ 이미 MA방식으로 표현되어있다. 즉,

$$\psi_1 = 0.5, \psi_2 = -0.3, \psi_k = 0, k = 3, 4, \dots$$

■ AR방식으로 표현하기 위해 후방연산자를 사용하면

$$Z_t = (1 - 0.5B + 0.3B^2 - \dots) a_t \Rightarrow (1 - 0.5B + 0.3B^2 - \dots)^{-1} Z_t = a_t$$

$$\Rightarrow (1 + 0.5B - 0.05B^2 - 0.175B^3 - \dots) Z_t = a_t$$

$$\Rightarrow Z_t = -0.5Z_{t-1} + 0.05Z_{t-2} + 0.175Z_{t-3} + \dots + a_t$$

따라서

$$\pi_1 = -0.5, \pi_2 = 0.05, \pi_3 = 0.175, \dots$$

$$\begin{array}{r}
1 \\
\hline
1 - 0.5B + 0.3B^2 + \dots
\end{array}$$

### 3. AR 모형과 MA 모형

- AR모형: 변수의 과거 값의 선형 결합을 통해서 예측을 수행. 자기 회귀(Auto-Regressive)라는 단어 속에 자기 자신에 대한 변수의 회귀라는 의미가 담겨있음. 따라서 차수 p의 자기 회귀 모모형은 다음과 같이 쓸 수 있음

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t$$

$\varepsilon_t$ 는 백색잡음( $\sim N(0, \sigma^2)$ ). p 자기 회귀 모형인 AR(p) 모델이라고 부름

- AR(1) / AR(2) 모형

\* AR(1) 모형 :

$$Z_t = \phi_1 Z_{t-1} + a_t$$

-정상성을 갖기 위한 조건:  $-1 < \phi < 1$

- $Z_t$ 는 일반적으로 평균을 0으로 가정함

\*AR(2) 모형 :

$$Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + a_t$$

-정상성을 갖기 위한 조건:

$$-1 < \phi_2 < 1, \phi_1 + \phi_2 < 1, \phi_2 - \phi_1 < 1$$

- AR 모형의 ACF/PACF

- AR(1) 모형의 ACF



- $Z_t = \phi_1 Z_{t-1} + a_t$   $-1 < \phi_1 < 1$
- $Var[Z_t] = \gamma(0) = \frac{\sigma_a^2}{1-\phi_1^2}$
- $\gamma(k) = \phi_1^k \gamma(0), k = 0, 1, 2, \dots$
- $\rho(k) = \frac{\gamma(k)}{\gamma(0)} = \phi_1^k, k = 0, 1, 2, \dots$

지수적으로 감소하는 패턴

→ 자기상관계수

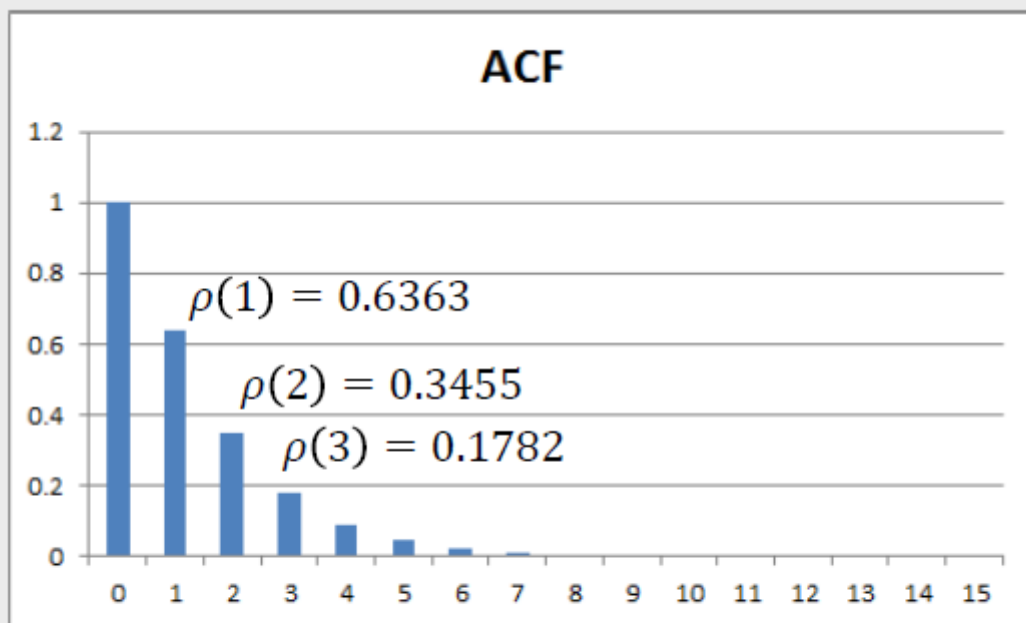
- AR(1) 모형의 PACF

- $P(1) = \rho(1) = \phi_1$
- $P(k) = 0, k = 2, 3, \dots$ : 시차 1 이후  
절단 패턴



- AR(1) 모형의 경우, ACF는 지수적으로 감소.  $|\phi| < 1$  이므로,  $\phi$ 의 exponential은 값이 계속 줄어드는 것임

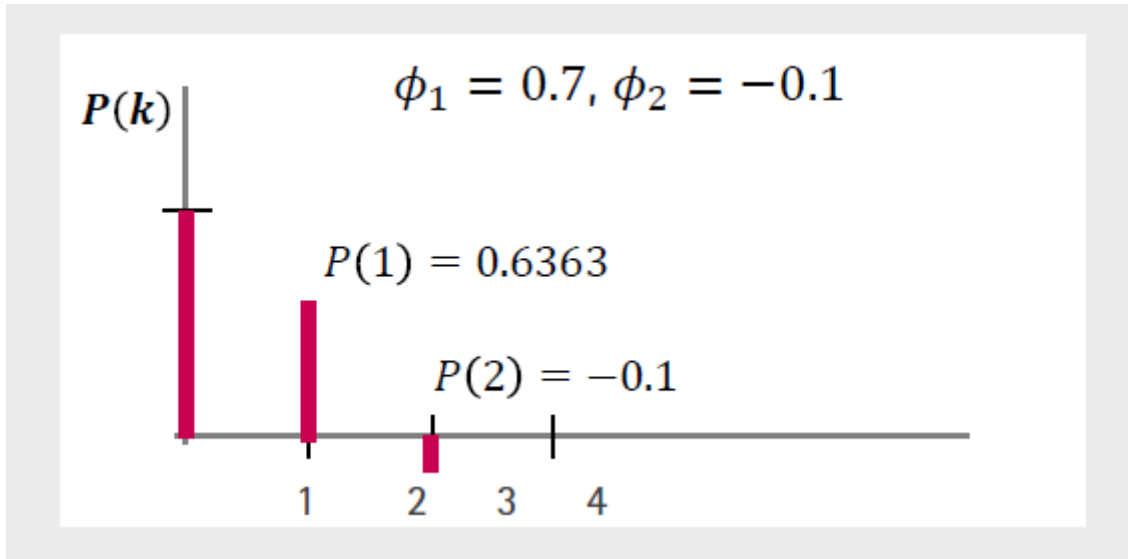
- PACF의 경우는, 1일 때의 값만 존재하고, 그 이후로는  $P(k)=0$ 으로 계산됨(절단 패턴)



$$\phi_1 = 0.7, \phi_2 = -0.1$$

- AR(2) 모형의 경우, 역시 ACF는 지수적으로 감소하는 패턴을 띠

- PACF는  $P(2)$  이후로 절단 패턴을 띠



- ACF/PACF의 기능 → 만약, ACF가 지수적으로 감소하고, PACF는  $k=2$ 까지만 값을 갖고 3 이후로는 0의 값을 갖는다면 우리가 가진 데이터는 AR(2)를 따르는 데이터라는 것을 유추할 수 있음. PACF에서 절단되는 지점을 통해 AR 모형의 차수  $p$ 를 결정할 수 있고, ACF의 형태를 통해 AR 모형인지 아닌지를 판단할 수 있음
- MA 모형: 회귀식에 변수의 과거 값을 이용하는 대신에, 과거 예측 오차를 이용함

$$y_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \cdots + \theta_q \varepsilon_{t-q}$$

$\varepsilon_t$ 는 백색잡음




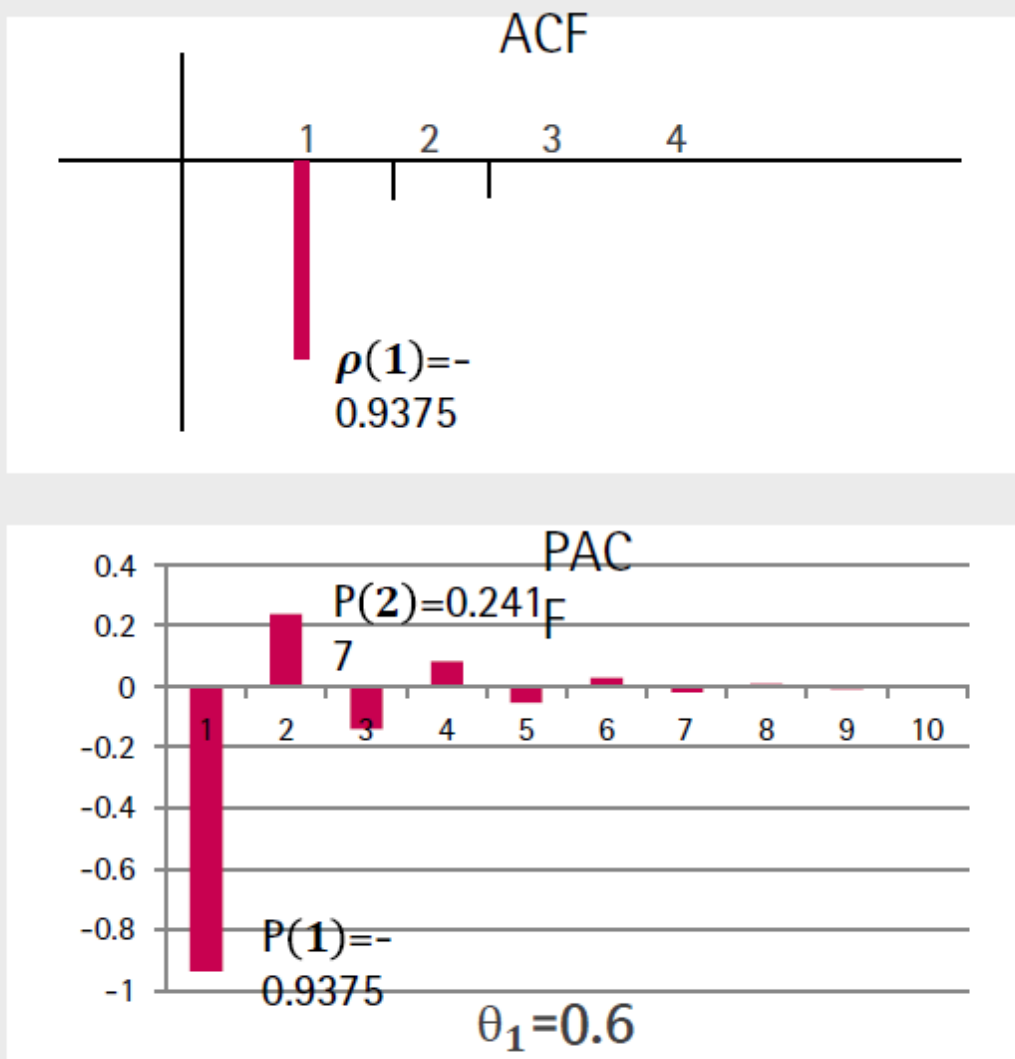
Figure 8.6: 매개변수를 다르게 설정한 이동 평균 모델로부터 얻은 데이터의 두 가지 예. 왼쪽:  $y_t = 20 + \varepsilon_t + 0.8\varepsilon_{t-1}$ 인 MA(1). 오른쪽:  $y_t = \varepsilon_t - \varepsilon_{t-1} + 0.8\varepsilon_{t-2}$ 인 MA(2). 두 가지 경우 모두,  $\varepsilon_t$ 는 평균이 0이고 분산이 1인 정규 분포를 따르는 백색잡음입니다.

- MA 모형의 가역성 조건

MA(1) 모형의 경우:  $-1 < \theta_1 < 1$ .

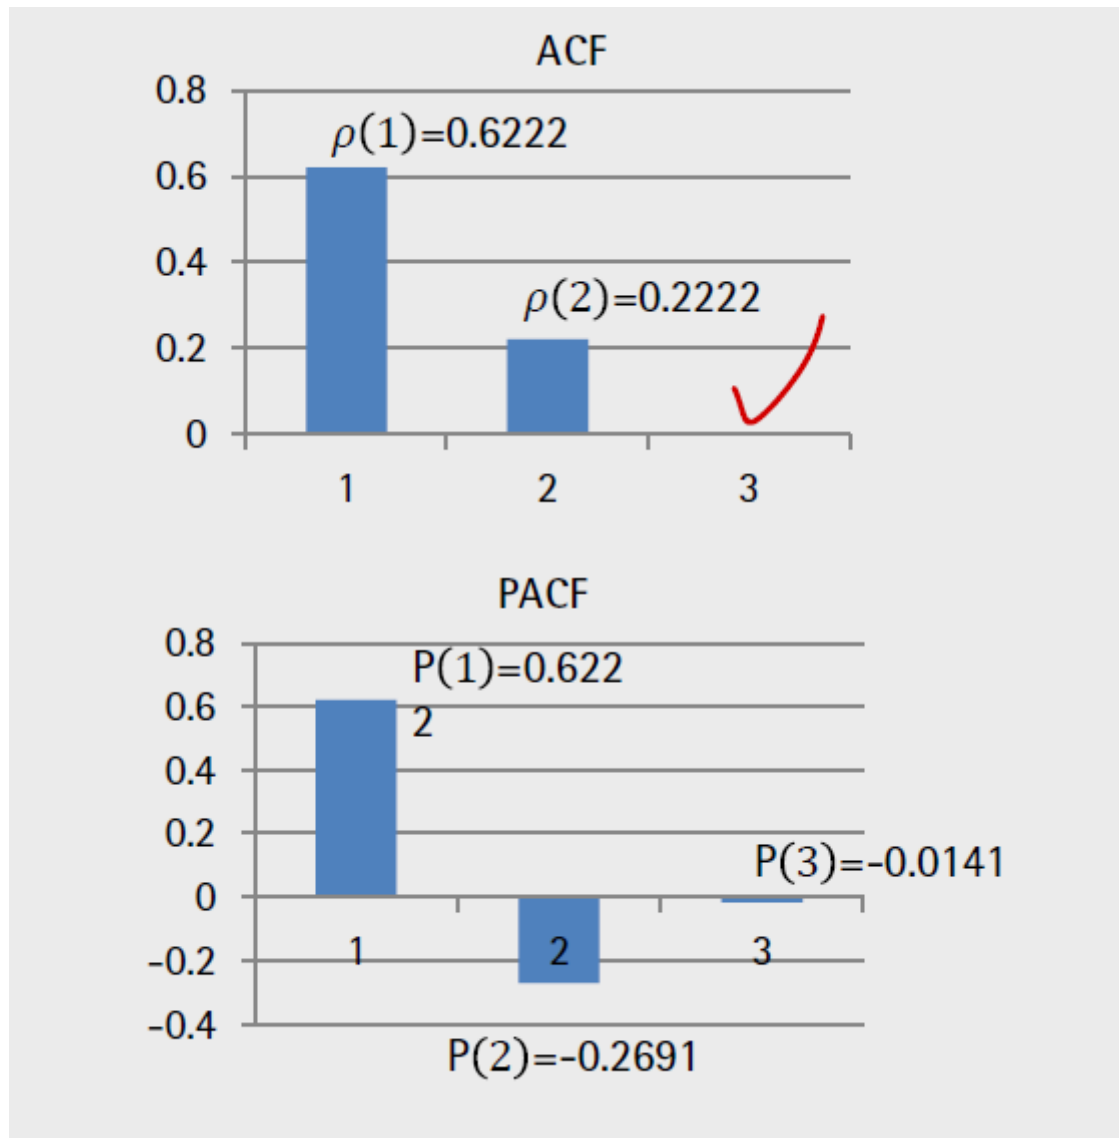
MA(2) 모형의 경우:  $-1 < \theta_2 < 1$ ,  $\theta_2 + \theta_1 > -1$ ,  $\theta_1 - \theta_2 < 1$

- MA 모형의 ACF와 PACF



- MA(1) 모형의 경우, ACF는  $K=1$  이후에서 절단 패턴을 띠
- PACF의 경우는 지수적으로 감소하는 패턴





- MA(2) 모형에서는 ACF는 2 이후에서 절단 패턴, PACF는 지수적으로 감소하는 패턴을 띠

- AR 모형과 MA 모형의 관계
  - 정상성을 나타내는 어떤 AR(p) 모형은 MA( $\infty$ ) 모형으로 쓸 수 있음.  
 예를 들어, AR(1) 모형의 경우 다음과 같은 식으로 변형할 수 있음  
 (정상성 조건에 의해, k가 커질수록  $\phi^k$ 의 값은 작아질 것임)  $\Rightarrow$  MA( $\infty$ ) 모형이 유도됨

$$\begin{aligned}
 y_t &= \phi_1 y_{t-1} + \varepsilon_t \\
 &= \phi_1 (\phi_1 y_{t-2} + \varepsilon_{t-1}) + \varepsilon_t \\
 &= \phi_1^2 y_{t-2} + \phi_1 \varepsilon_{t-1} + \varepsilon_t \\
 &= \phi_1^3 y_{t-3} + \phi_1^2 \varepsilon_{t-2} + \phi_1 \varepsilon_{t-1} + \varepsilon_t \\
 &\text{etc.}
 \end{aligned}$$

$$y_t = \varepsilon_t + \phi_1 \varepsilon_{t-1} + \phi_1^2 \varepsilon_{t-2} + \phi_1^3 \varepsilon_{t-3} + \dots$$

뿐만 아니라, 어떤 가역적인 MA(q) 모형은 AR( $\infty$ ) 모형으로 쓸 수 있음

#### 4. ARMA 모형

- ARMA(1,1) 모형: AR(1) 모형과 MA(1) 모형의 복합 형태
- 시점 t의 값은 시점 t-1의 값, 시점 t와 t-1의 오차항(백색잡음)으로 생성됨
- 정상성 조건:  $-1 < \phi < 1$
- 가역성 조건:  $-1 < \theta_1 < 1$

#### • ARMA(p,q) 모형의 특징



- (1)  $p \geq q+1$  일 때, ACF는 AR(p) 모형과 유사하게 0으로 다가감
- (2)  $p \leq q$  일 때, q-p개의 값은 특정 값을 가지고 이후로는 0으로 다가감
- (3)  $p \geq q+1$  일 때, PACF는 p-q개는 특정 값을 가지고 이후로는 MA(q) 모형과 유사하게 0으로
- (4)  $p \leq q$  일 때, 처음부터 MA(q) 모형과 유사하게 0으로 다가감

#### <sup>p=2</sup> ARMA(1,3) 모형 vs ARMA(3,1) 모형

##### • ARMA(1,3) 모형

$$Z_t - 0.7Z_{t-1} = a_t - 0.7a_{t-1} - 0.2a_{t-2} - 0.5a_{t-3}$$

q-p=2이므로 ACF의 처음 2개는 별개 값이고 그 이후 지수적으로 감소;  
PACF는 처음부터 지수적으로 감소





## ARMA(3,1) 모형 vs ARMA(1,3) 모형

### • ARMA(3,1) 모형

$$Z_t - 0.7Z_{t-1} + 0.1Z_{t-3} = a_t - 0.5a_{t-1}$$

$$\rho(k) = 0.7\rho(k-1) - 0.2\rho(k-3), \quad k = 2, 3, 4, \dots$$

$p-q=2$ 이므로 ACF의 처음부터  
지수적으로 감소; PACF는 처음  
2개는 별개 값이며 그 이후 지수  
적으로 감소



### [ARMA 모형의 표현 요약]

시계열 데이터  $X_t$ 가 정상성을 만족하고  $ARMA(p, q)$  모형을 따른다고 한다면 아래의 관계식을 만족한다.

$$X_t = c + \sum_{i=1}^p \phi_i X_{t-i} + Z_t - \sum_{i=1}^q \theta_i Z_{t-i} \quad (1.1)$$

여기서  $Z_t$ 는 정규분포를 따르는 백색 잡음이다. 즉,  $Z_t$  i.i.d.  $\sim N(0, \sigma^2)$  이다.

이때  $B$ 를 Back Shift 연산자라고 하자. 즉,  $BX_t = X_{t-1}$ 이고  $B^p X_t = X_{t-p}$ 이다. 이 연산자를 이용하면 식 (1.1)을 아래와 같이 표현할 수 있다.

$$(1 - \phi_1 B - \dots - \phi_p B^p)X_t = c + (1 - \theta_1 B - \dots - \theta_q B^q)Z_t \quad (1-1)$$

### • ARMA 모형 정리

- 시계열 데이터 설명을 위해 AR/MA 중 하나의 방식으로 표현하는 것보다 모수를 절약하는 효과를 볼 수 있음
- 차수를 정하기 위해서는, AR은 PACF 함수에서 특정 기준선을 훌쩍 뛰어넘는 막대의 개수, MA는 ACF 함수에서 특정 기준선을 훌쩍 뛰어넘는 막대의 개수에 따라 결정할 수 있음

(참고)

ARMA 모형의 ACF는 AR과 MA의 특징이 모두 나타난다.

ACF는 지수적으로 감소하는 모습을 보이고 (AR의 특성), PACF에는 음의 상관성도 나타난다. (MA의 특성) 어떤 시계열의 ACF가 이런 모습을 보이고 있으면, 그 시계열은 ARMA 모형에 가까울 가능성이 있다.

