

# ARMA 모형의 식별

- 모형의 식별, 추정 및 검증 과정

- 단계 1: 시계열 데이터를 그래프로 나타내어 시각적으로 관찰하고 정상성 여부를 검토한다. 비정상적인 경우에는 추세제거, 계절성제거, 분산안정화 등을 통하여 정상적 시계열로 변환한다. (이 부분은 비정상적 시계열에서 설명).
- 단계 2. 시계열 데이터에 대한 표본 ACF 및 표본 PACF를 산출하고 정상성 여부를 확인한다. 비정상적인 경우 단계 1을 반복한다.
- 단계 3. (모형의 식별) 표본 ACF 및 표본 PACF를 다양한 ARMA모형들의 이론적 ACF 및 PACF와 비교하여 ARMA모형의 차수인  $p$ 와  $q$ 를 구한다.
- 단계 4. (모형의 추정) 단계 3에서 얻은 모형에 대한 계수들을 추정하고 잔차(residual)를 구한다.
- 단계 5. (모형의 검증) 잔차가 백색잡음을 따르는지 검정한다. 잔차가 백색잡음을 따르면 단계 3의 모형이 제대로 식별되었으며, 아니면 다른 차수  $p$ 와  $q$ 를 구한 후 과정을 반복한다.

# 표본 ACF 및 표본 PACF

- 표본 ACF 산출 (단계 2 관련) (정비) \* 시계열 2과 1.4.4.

시계열 데이터:  $Z_1, \dots, Z_n$

- 표본 분산

$$\hat{\gamma}(0) = \frac{1}{n} \sum_{t=1}^n (Z_t - \bar{Z})^2$$

- 시차 k 표본 자기공분산

$$\hat{\gamma}(k) = \frac{1}{n} \sum_{t=1}^{n-k} (Z_t - \bar{Z})(Z_{t+k} - \bar{Z}), k = 1, 2, \dots$$

- 표본 ACF

$$\hat{\rho}(k) = \frac{\hat{\gamma}(k)}{\hat{\gamma}(0)} = \frac{\sum_{t=1}^{n-k} (Z_t - \bar{Z})(Z_{t+k} - \bar{Z})}{\sum_{t=1}^n (Z_t - \bar{Z})^2}, k = 1, 2, \dots$$

- 표준오차 (바틀렛 근사식 사용)

$$se(\hat{\rho}(k)) = \sqrt{\frac{1}{n} [1 + 2\hat{\rho}^2(1) + \dots + 2\hat{\rho}^2(m)]}$$

ACF

$$\gamma(0) = \text{Var}[Z_t]$$

$$\gamma(k) = E[Z_t Z_{t-k}]$$

$$\rho(k) = \frac{\gamma(k)}{\gamma(0)}$$

$k < n$

$$\hat{\rho} \approx N(\rho, n^{-1}W)$$

\* 2과 53페이지

W: covariance matrix

$$W_{ij} = \sum_{k=-\infty}^{\infty} \{ \rho(k+i)\rho(k+j) + \rho(k-i)\rho(k+i) + 2\rho(i)\rho(j)\rho^2(k) - 2\rho(i)\rho(k)\rho(k+j) - 2\rho(i)\rho(k)\rho(k+i) \}$$

# 표본 ACF 및 표본 PACF

- 표본 PACF 산출 (단계 2 관련)

- 시차별 PACF는 ACF로 표현되므로 ACF를 추정하여 표본 PACF를 구할 수 있다.
- Durbin (1960)이 제안한 반복적 공식 사용

$$\hat{P}(1) = \hat{\phi}_{11} = \hat{\rho}(1)$$

$$\hat{P}(k) = \hat{\phi}_{kk} = \frac{\hat{\rho}(k) - \sum_{j=1}^{k-1} \hat{\phi}_{k-1,j} \hat{\rho}(k-j)}{1 - \sum_{j=1}^{k-1} \hat{\phi}_{k-1,j} \hat{\rho}(j)}, k = 2, 3, \dots$$

여기서

$$\hat{\phi}_{k,j} = \hat{\phi}_{k-1,j} - \hat{\phi}_{k,k} \hat{\phi}_{k-1,k-j} \quad j = 1, 2, \dots, k-1$$

→ 엑셀에서 손으로 계산

# 표본 ACF 및 표본 PACF

$$\hat{f}(0) = \frac{8.6382}{15} \quad \hat{f}(k) = \frac{1}{15} \sum_{t=1}^{n-k} (z_t - \bar{z})(z_{t+k} - \bar{z})$$

(예 3.1) 다음의 시계열 데이터에 대한 표본 ACF를 구하라.

$$\hat{\rho}(k) = \frac{\hat{\gamma}(k)}{\hat{\gamma}(0)} = \frac{\sum_{t=1}^{n-k} (z_t - \bar{z})(z_{t+k} - \bar{z})}{\sum_{t=1}^n (z_t - \bar{z})^2}$$

$$\bar{z} = -0.11$$

$$\hat{\gamma}(0) = \frac{1}{15} [(-1.01 + 0.11)^2 + (-0.81 + 0.11)^2 + \dots + (-0.22 + 0.11)^2]$$

$$= \frac{8.6382}{15} = 0.5759$$

$$\hat{\rho}(1) = \frac{1}{8.6382} [(-1.01 + 0.11)(-0.81 + 0.11) + \dots + (-0.41 + 0.11)(-0.22 + 0.11)]$$

$$= \frac{4.1431}{8.6382} = 0.4796$$

$$\hat{\rho}(2) = \frac{1}{8.6382} [(-1.01 + 0.11)(-0.33 + 0.11) + \dots + (0.10 + 0.11)(-0.22 + 0.11)]$$

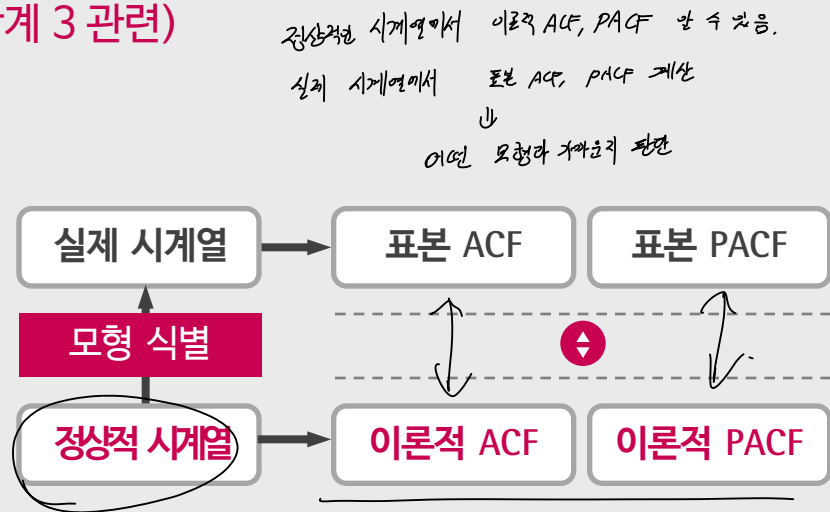
$$= \frac{1.3848}{8.6382} = 0.1603$$

	$Z_t$		$Z_t$
1	-1.01	9	1.30
2	-0.81	10	1.08
3	-0.33	11	-0.33
4	-0.40	12	0.31
5	-0.95	13	0.10
6	-1.33	14	-0.41
7	0.72	15	-0.22
8	0.63		

# ARMA 모형의 식별

- ARMA모형의 이론적 ACF와 PACF의 패턴 (단계 3 관련)

모형	ACF	PACF
AR(p)	지수적으로 감소	시차 p 이후 절단
MA(q)	시차 q 이후 절단	지수적으로 감소
ARMA(p, q)	시차 (q-p) 이후 지수적 감소	시차 (p-q) 이후 지수적 감소




# ARMA 모형의 식별

즉시나 제2차원 모형으로 판별.

## 예 3.2 (나일강 유량)

다음 그림은 1872년부터 1970년까지의 나일강 (Nile river) 연간평균 유량 데이터를 나타낸다. 본 데이터에 적합한 모형을 식별해 보자.

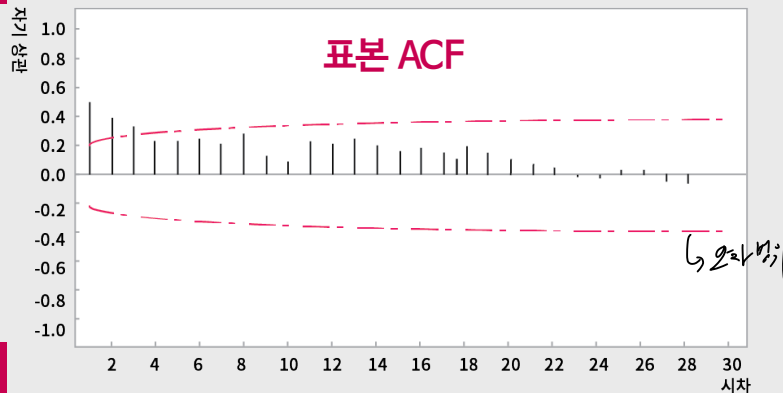


# ARMA 모형의 식별

## 예 3.2 계속 (나일강 유량)


### 단계2

nile flow에 대한 자기 상관 함수  
(자기 상관에 대한 5% 유의 한계)



### 단계3

nile flow에 대한 편 자기 상관 함수  
(편 자기 상관에 대한 5% 유의 한계)

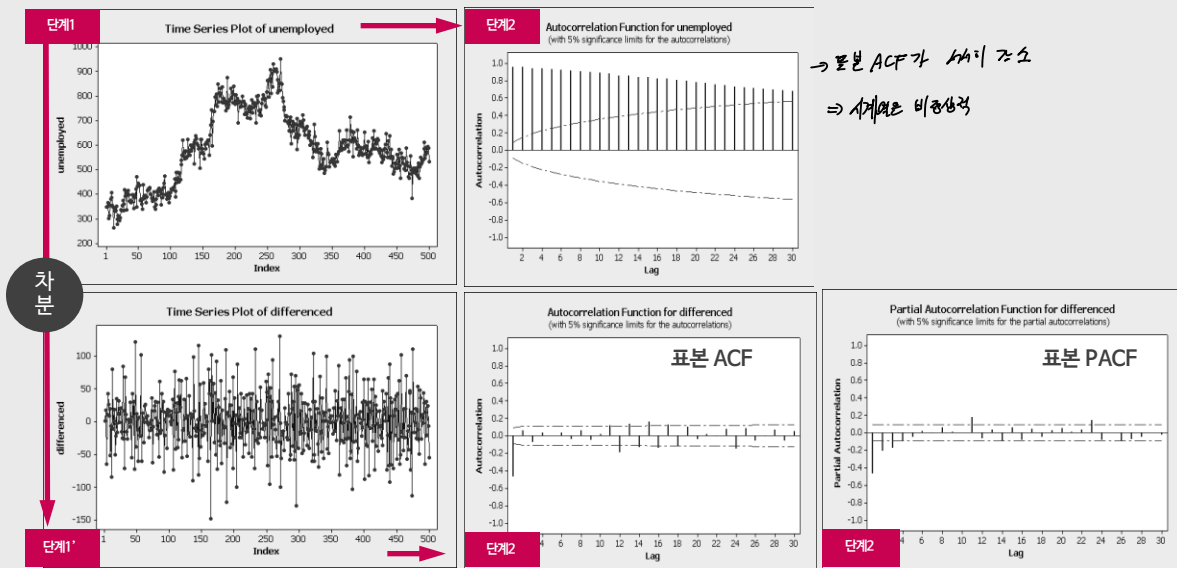


- 표본 ACF는 지수적으로 감소하고 표본 PACF는 시차 1 또는 2 이후 절단되므로 AR(1) 또는 AR(2) 모형으로 보임
- 즉,  $p=1$  또는  $2$ ;  $q=0$

# ARMA 모형의 식별

## 예 3.3(미국 여성 실업자수)

- 다음 그림은 1961-2002년 사이 월별 미국의 16-19세 젊은 여성 실업자수를 나타낸다.



\* 구분: 1차 시계열과 2차 시계열의 차이가  
원 시계열의 차이 지수적으로 감소



# 시계열 모형 추정방법

- 최소자승법 (least squares method): AR모형의 경우 가능
- 비선형 최소자승법 (nonlinear least squares method): ARMA모형에 적용
- 최우 추정법 (maximum likelihood estimation)
  - 오차항이 서로 독립인 정규분포를 따르므로 우도함수 (likelihood function)을 유도하여 이를 최대로 하는 모형 계수들을 추정. ARMA 모형의 경우 정확한 우도함수 도출이 어렵고 초기치에 대한 가정이 필요.
  - 정확한 우도함수
    - 조건있는 우도함수: 임의로 초기치 가정하여 사용
    - 조건없는 우도함수: 과거의 초기치를 후방예측 (backcasting)하여 사용

# 최우추정법

- 정확한 우도함수

- 평균  $\mu$ , 분산  $\sigma^2$ 의 정규분포를 따르는 확률변수  $X$ 에 대한 관측치  $(x_1, \dots, x_n)$ 가 있다하자.
- 이 때 관측치는 서로 독립이므로  $n$ 개 관측치의 결합확률분포는 정규확률밀도함수의 곱으로 표현됨

$$f(x_1, \dots, x_n) = f(x_1)f(x_2) \cdots f(x_n) = \prod_{i=1}^n \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{(x_i - \mu)^2}{2\sigma^2}\right]$$

- 관측 데이터를 대입하면 모수  $\mu$ 와  $\sigma^2$ 의 함수로 간주할 수 있으며 이를 우도함수라 함.

$$L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{(x_i - \mu)^2}{2\sigma^2}\right] = \left(\frac{1}{2\pi\sigma^2}\right)^{\frac{n}{2}} e^{-\frac{\sum (x_i - \mu)^2}{2\sigma^2}}$$

- 이 우도함수를 최대로 하는 모수  $\mu$ 와  $\sigma^2$ 를 추정하는 방법을 최우추정법이라 함.
- 로그함수를 취한 로그우도함수를 최대로 하는 것이 편함

$$\log L(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi) - n \log(\sigma) - \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2}$$

$$L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} = \left(\frac{1}{2\pi\sigma^2}\right)^{\frac{n}{2}} \cdot e^{-\frac{\sum (x_i - \mu)^2}{2\sigma^2}}$$

$$\ln L(\mu, \sigma^2) = -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \sigma^2 - \frac{\sum (x_i - \mu)^2}{2\sigma^2}$$

$$\frac{\partial}{\partial \mu} \ln L = \frac{\sum (x_i - \mu)}{\sigma^2} = \frac{1}{\sigma^2} \sum (x_i - \mu) = \frac{n}{\sigma^2} (\bar{x} - \mu) = 0 \quad \mu = \bar{x}$$

$$\frac{\partial}{\partial \sigma^2} \ln L = -\frac{n}{2\sigma^2} + \frac{\sum (x_i - \mu)^2}{2\sigma^4} = 0 \quad \sigma^2 = \frac{1}{n} \sum (x_i - \mu)^2$$

$$* \frac{\partial^2}{\partial \mu \partial \mu} \ln L, \quad \frac{\partial^2}{\partial \mu \partial \sigma^2} \ln L, \quad \frac{\partial^2}{\partial \sigma^2 \partial \sigma^2} \ln L \text{ 이 4로 확인}$$

# 최우추정법

- ARMA모형의 경우 관측치  $(Z_1, Z_2, \dots, Z_n)$ 들은 서로 독립이 아니므로 이에 대한 우도함수의 구성이 어렵다.
- 대신 백색잡음  $(a_1, a_2, \dots, a_n)$ 이 서로 독립임을 활용하여 이에 대한 우도함수를 구성한다.

$$L(\theta; a_1, \dots, a_n) = (2\pi\sigma_a^2)^{-n/2} \exp\left(-\frac{1}{2\sigma_a^2} \sum_{t=1}^n a_t^2\right)$$

$$L(\mu, \sigma^2) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left(-\frac{\sum (x_i - \mu)^2}{2\sigma^2}\right)$$

- (예 - AR(1) 모형)  $Z_t = \phi_1 Z_{t-1} + a_t$ 
  - $a_t = Z_t - \phi_1 Z_{t-1}$
  - $a_1 = Z_1 - \phi_1 \textcircled{Z_0}$  (즉,  $a_1$ 을 구하기 위해 초기치  $Z_0$  필요)
- 초기치 처리 방법

- 적절한 가정으로 초기치 결정  $\Rightarrow$  조건있는 우도함수 (conditional likelihood function)
- 초기치를 예측하여 사용  $\Rightarrow$  조건없는 우도함수 (unconditional likelihood function)

# 조건있는 우도함수

- $(a_1, a_2, \dots, a_n)$ 의 로그 우도함수

$$\log L(\theta | a_1, \dots, a_n) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma_a^2 - \frac{\sum_{t=1}^n a_t^2}{2\sigma_a^2}$$

- ARMA (p,q) 모형에서  $(a_1, a_2, \dots, a_n)$  산출

$$a_t = \theta_1 a_{t-1} + \dots + \theta_q a_{t-q} + Z_t - \phi_1 Z_{t-1} - \dots - \phi_p Z_{t-p}$$

$$a_1 = \theta_1 a_0 + \dots + \theta_q a_{1-q} + Z_1 - \phi_1 Z_0 - \dots - \phi_p Z_{1-p}$$

다음의 초기치 필요

$$a_* = (a_{1-q}, \dots, a_{-1}, a_0) = (0, \dots, 0, 0)$$

$$z_* = (z_{1-p}, \dots, z_{-1}, z_0) = (\tilde{z}, \dots, \tilde{z}, \tilde{z})$$

초기 조건하에서 로그 우도함수

$$\log L_*(\theta | a_1, \dots, a_n) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma_a^2 - \frac{S_*(\theta)}{2\sigma_a^2}$$

조건제곱합

$$S_*(\theta) = \sum_{t=1}^n a_t^2(\theta | a_*, z_*, z_1, \dots, z_n) \Rightarrow \text{최소화} \Rightarrow \hat{\theta} \Rightarrow \hat{\sigma}_a^2 = \frac{S_*(\hat{\theta})}{df} \quad (df = n - 2p - q - 1)$$

# 조건있는 우도함수

(예- AR(1) 모형) 다음 10개 시계열 데이터가 AR(1)모형을 따른다.

-0.17, 0.24, -0.51, 1.10, 0.08, 0.32, -0.44, -1.16, -0.58, -0.28

$\phi_1 = 0.2$ 와  $\phi_1 = 0.4$  일때 조건제곱합을 각각 구하라.

(풀이)

$$\phi_1 = 0.2: a_t = Z_t - 0.2Z_{t-1}$$

$$\phi_1 = 0.4: a_t = Z_t - 0.4Z_{t-1}$$

$z_0 = 0$  가정

$$S_*(\phi_1 = 0.2) = 3.5234 \quad \checkmark$$

$$S_*(\phi_1 = 0.4) = 3.7106$$


회귀 분석을 통해 각각의 회귀계수  $\phi_1$ 를 구한 후, 이를 이용하여  $a_t$ 를 구한다.

$Z_t$	$\phi_1 = 0.2$		$\phi_1 = 0.4$	
	$a_t$	$a_t^2$	$a_t$	$a_t^2$
-0.17	-0.17	0.0289	-0.17	0.0289
0.24	0.274	0.0751	0.308	0.0949
-0.51	-0.558	0.3114	-0.606	0.3672
1.1	1.202	1.4448	1.304	1.7004
0.08	-0.14	0.0196	-0.36	0.1296
0.32	0.304	0.0924	0.288	0.0829
-0.44	-0.504	0.2540	-0.568	0.3226
-1.16	-1.072	1.1492	-0.984	0.9683
-0.58	-0.348	0.1211	-0.116	0.0135
-0.28	-0.164	0.0269	-0.048	0.0023

# 조건없는 우도함수

- 조건없는 우도함수  $\rightarrow$  필요한 것끼리 예측

$$\log L(\theta|z_1, \dots, z_n) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma_a^2 - \frac{S(\theta)}{2\sigma_a^2}$$



- 조건없는 제곱합

$$S(\theta) = \sum_{t=-M}^n E^2[a_t|\theta; z_1, \dots, z_n] \quad (M: \text{과거치 예측수})$$

백색잡음의 기대치로 오차항 예측 - 이때 과거 관측치 예측 필요

- 과거값 예측에 후방예측 (backcasting) 사용 - 시간축을 반대방향으로 생각  $\Rightarrow$  라지를 미래치로 생각

$$\begin{aligned} Z_t &= \phi_1 Z_{t-1} - \dots - \phi_p Z_{t-p} + a_t - \theta_1 a_{t-1} - \dots - \theta_q a_{t-q} \\ \Rightarrow Z_t &= \phi_1 Z_{t+1} - \dots - \phi_p Z_{t+p} + b_t - \theta_1 b_{t+1} - \dots - \theta_q b_{t+q} \\ &\Rightarrow \text{미래값 (관측치)으로 과거값 예측} \end{aligned}$$

- 예 -AR(1)모형  $Z_t = \phi_1 Z_{t-1} + a_t \Leftrightarrow Z_t = \phi_1 Z_{t+1} + b_t$

$$E[a_0] = E[Z_0] - \phi_1 E[Z_{-1}]$$

$$E[Z_0] = \phi_1 E[Z_1] + E[b_0] = \phi_1 z_1$$

$$E[Z_{-1}] = \phi_1 E[Z_0] + E[b_{-1}] = \phi_1 \phi_1 z_1$$

# 조건없는 우도함수

(예- AR(1))다음 10개 시계열 데이터가 AR(1)모형을 따른다.

-0.17, 0.24, -0.51, 1.10, 0.08, 0.32, -0.44, -1.16, -0.58, -0.28

$\phi_1 = 0.2$ 와  $\phi_1 = 0.4$  일때 조건없는 제곱합을 각각 구하라.

$$S(\theta) = \sum_{t=-M}^n E^2[a_t|\theta; z_1, \dots, z_n]$$

- $Z_t = \phi_1 Z_{t-1} + a_t \Leftrightarrow Z_t = \phi_1 Z_{t+1} + b_t$
- $E[a_t] = Z_t - \phi_1 Z_{t-1}, t = 2, 3, \dots$
- $E[a_1] = E[Z_1] - \phi_1 E[Z_0] = (1 - \phi_1^2)z_1$
- $E[a_{-j}] = \phi_1^{j+1}(1 - \phi_1^2)z_1, j = 0, 1, 2, \dots$
- $S(\phi_1 = 0.2) = 3.5236$
- $S(\phi_1 = 0.4) = 3.7060$

$Z_t$		$\phi_1 = 0.2$		$\phi_1 = 0.4$	
		$a_t$	$a_t^2$	$a_t$	$a_t^2$
-3	-	-0.0040	0.0000	-0.00366	0.0000
-2	-	-0.0100	0.0001	-0.00914	0.0001
-1	-	-0.0250	0.0006	-0.02285	0.0005
0	-	-0.0626	0.0039	-0.05712	0.0033
1	-0.17	-0.1564	0.0245	-0.1428	0.0204
2	0.24	0.2740	0.0751	0.308	0.0949
3	-0.51	-0.5580	0.3114	-0.606	0.3672
4	1.1	1.2020	1.4448	1.304	1.7004
5	0.08	-0.1400	0.0196	-0.36	0.1296
6	0.32	0.3040	0.0924	0.288	0.0829
7	-0.44	-0.5040	0.2540	-0.568	0.3226
8	-1.16	-1.0720	1.1492	-0.984	0.9683
9	-0.58	-0.3480	0.1211	-0.116	0.0135
10	-0.28	-0.1640	0.0269	-0.048	0.0023

$S(\phi=0.2)$

$S(\phi=0.4)$



# ARMA 모형의 추정

- 예 (나일강 유량) 본 시계열이 AR(2)모형을 따른다고 식별되므로 다음의 모형 추정

$Z_t = c + \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + a_t$  추정 결과는 다음과 같다.

	추정치	표준오차	t-값	p-값
상수 ( $c$ )	357.5	14.55	24.56	0.000
AR1 ( $\phi_1$ )	0.4039	0.1000	4.04	0.000
AR2 ( $\phi_2$ )	0.2064	0.1006	2.05	0.043

- 두 계수  $\phi_1, \phi_2$ 의 추정치는 유의수준 5%에서 유의
- 추정식은 다음과 같다.  $\hat{Z}_t = 357.5 + 0.4039Z_{t-1} + 0.2064Z_{t-2}$

$$\hat{\sigma}_a^2 = MSE = 20943$$

#1  
유이한 2 카인

# ARMA 모형의 검증

## • 모형의 검증

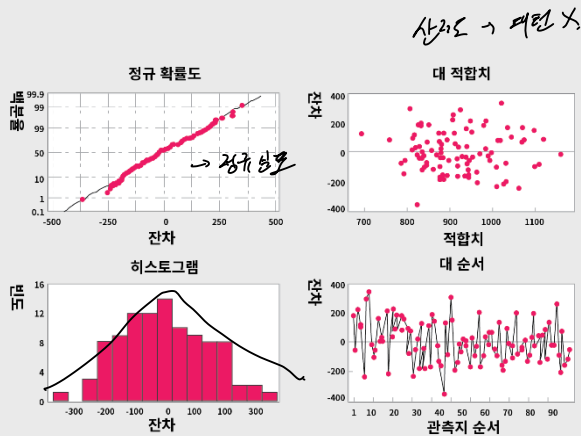
- 모형의 오차항이 평균 0, 분산  $\sigma_a^2$ 의 정규분포를 따르는 백색잡음이라 가정하고 있기 때문에 이에 대한 검증이 필요
- 잔차에 대하여 다음을 확인
  - ▶ 정규성: 정규확률도표 활용
  - ▶ 등분산성 및 패턴 유무: 잔차 산점도 활용
  - ▶ 랜덤성:
    - ✓ ACF/PACF로 시차별 상관계수가 모두 0인지 확인
    - ✓ 포트만토 검정 (portmanteau test): 시차별 자기상관계수가 모두 0인지 검정 (Ljung-Box 검정 등 사용)

잔차가 랜덤성을 가지면 모든 시차에 대해 모든 ACF, PACF가 0



\* 2레 page 30.

# ARMA 모형의 식별과 추정

- 예 (나일강 유량)



nile\_flow의 잔차 그림




# ARMA 모형의 식별과 추정

- 예 (나일강 유량)

- 정규확률도를 볼 때 잔차가 정규분포를 따름
- 잔차 산점도로 부터 등분산성, 패턴없음이 관찰


nile\_flow의 잔차 그림

정규 확률도




대 적합치


산점도 → 패턴 X



히스토그램



대 순서




# ARMA 모형의 식별과 추정

- 예 (나일강 유량)


- 잔차에 대한 ACF/PACF로 부터 백색잡음 확인

nile\_flow에 대한 잔차의 ACF  
(자기 상관에 대한 5% 유의 한계)



9.24.17.3.14

nile\_flow에 대한 잔차의 PACF  
(편 자기 상관에 대한 5% 유의 한계)



# ARMA 모형의 식별과 추정

- 포트만토 (Ljung-Box) 검정

시차	12	24	36	48
카이제곱	11.9	16.6	25.0	37.3
자유도	9	21	33	45
p-값	0.222	0.735	0.841	0.787

- 포트만토 검정에서 시차별 자기상관이 없음의 귀무가설을 채택
- 즉, 잔차에 시차별 자기상관이 없다고 판정


p값이 크다 → 채택하지 않는다.

자기상관이 없다는 귀무가설 기각 못함.

# 시계열 예측

모형을 식별하고 모수 추론 후 미래값 예측

## 최소 평균제곱오차 예측치



- 관측치:  $Z_1, \dots, Z_n$

- $f_{n,k}$  ( $k=1,2,\dots$ ): 시점  $n$ 에서  $k$ 시점 이후 (즉,  $n+k$  시점) 시계열 예측치
- 과거 시계열 관측치의 선형결합으로 예측

$$f_{n,k} = b_k Z_n + b_{k+1} Z_{n-1} +$$

$$\Downarrow Z_t = a_t - \psi_1 a_{t-1} - \psi_2 a_{t-2} - \dots \quad (\text{MA 표현 방법})$$

$$f_{n,k} = c_k a_n + c_{k+1} a_{n-1} + \dots$$

- 평균제곱오차 (mean squared error)

$$\begin{aligned} Q &= E[(Z_{n+k} - f_{n,k})^2] = E\left[\left(\sum_{j=0}^{\infty} \psi_j a_{n+k-j} - \sum_{j=k}^{\infty} c_j a_{n+k-j}\right)^2\right] \\ &= \sigma_a^2 \sum_{j=0}^{k-1} \psi_j^2 + \underbrace{\sigma_a^2 \sum_{j=0}^{\infty} (\psi_{j+k} - c_{j+k})^2}_{\text{최소}} \end{aligned}$$

# 시계열 예측

## 최소 평균제곱오차 예측치

- $Q$ 를 최소로 하는  $c_{j+k}$ 의 추정치

$$\hat{c}_{j+k} = \psi_{j+k}, k = 1, 2, \dots$$

$$f_{n,k} = \psi_k a_n + \psi_{k+1} a_{n-1} + \dots$$

$$f_{n,k} = E[Z_{n+k} | Z_n, Z_{n-1}, \dots]: k \text{시점 이후 예측치는 조건부 기대치와 동일}$$

× 시점  $n$ 까지 관측치로 구성된 주어진 데이터

해당 예측값은 시점  $n+k$ 에서 시계열에 대한 가설값이 됨.

- 예측오차

$$e_{n,k} = Z_{n+k} - f_{n,k} = a_{n+k} + \psi_1 a_{n+k-1} + \dots + \psi_{k-1} a_{n+1}, k = 1, 2, \dots$$

예측오차 분산

$$v_{n,k} = \text{Var}[e_{n,k}] = \sigma_a^2 \sum_{j=0}^{k-1} \psi_j^2$$

$$v_{n,k} = \text{Var}[Z_{n+k} | Z_n, Z_{n-1}, \dots]: k \text{시점 이후 예측오차분산은 조건부 분산과 동일}$$



# ARMA모형 예측

- 예측식: 시점  $n$ 까지의 과거 데이터로 부터 미래 시점 예측은 조건부 기대치 사용
  - 한단계 예측식:  $f_{-}(n,1)=E[Z_{-}(n+1) \mid Z_{-}n, Z_{-}(n-1), \dots]$
  - $k$ -단계 예측식:  $f_{-}(n,k)=E[Z_{-}(n+k) \mid Z_{-}n, Z_{-}(n-1), \dots]$ ,  $k=1, 2, \dots$
  - 계수는 추정값 이용, 과거 오차항은 잔차를 이용하여 추정
- 예측오차 분산: 예측구간이 필요한 경우 사용
  - 한단계 예측오차:  $e_{-}(n,1)=Z_{-}(n+1)-f_{-}(n,1)=a_{-}(n+1)$
  - $k$ -단계 예측오차:  $\tilde{e}_{-}(n,k)=Z_{-}(n+k)-f_{-}(n,k)$
  - 한단계 예측오차 분산:  $\text{Var}[e_{-}(n,1)] = \text{Var}[a_{-}(n+1)] = \sigma_a^2$   $\sigma_a^2$
  - $k$ -단계 예측오차 분산:  $\text{Var}[e_{-}(n,k)] = \text{Var}[Z_{-}(n+k) \mid Z_{-}n, Z_{-}(n-1), \dots]$ ,  $k=1, 2, \dots$

# ARMA모형 예측

## AR모형의 예측

- AR(2) 모형:  $Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + a_t$ 
  - 한단계 예측식:  $f_{n,1} = E[Z_{n+1} | Z_n, Z_{n-1}, \dots] = \phi_1 Z_n + \phi_2 Z_{n-1}$  ( $a_{n+1}$  기대치는 0)
  - 2-단계 예측식:  $f_{n,2} = E[Z_{n+2} | Z_n, Z_{n-1}, \dots] = \phi_1 f_{n,1} + \phi_2 Z_n$
  - 한단계 예측오차 분산:  $\text{Var}[e_{n,1}] = \sigma_a^2$
  - 2-단계 예측오차 분산:  $\text{Var}[e_{n,2}] = \text{Var}[Z_{n+2} | Z_n, Z_{n-1}, \dots] = (1 + \phi_1^2) \sigma_a^2$
- AR(4) 모형:  $Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + \dots + \phi_4 Z_{t-4} + a_t$ 
  - 한단계 예측식:  $f_{n,1} = E[Z_{n+1} | Z_n, Z_{n-1}, \dots] = \phi_1 Z_n + \phi_2 Z_{n-1} + \dots + \phi_4 Z_{n-3}$
  - 2-단계 예측식:  $f_{n,2} = E[Z_{n+2} | Z_n, Z_{n-1}, \dots] = \phi_1 f_{n,1} + \phi_2 Z_n + \phi_3 Z_{n-1} + \phi_4 Z_{n-2}$
  - 한단계 예측오차 분산:  $\text{Var}[e_{n,1}] = \sigma_a^2$
  - 2-단계 예측오차 분산:  $\text{Var}[e_{n,2}] = \text{Var}[Z_{n+2} | Z_n, Z_{n-1}, \dots] = (1 + \phi_1^2) \sigma_a^2$

# ARMA모형 예측

(예- AR(2) 모형) 시점 1에서 20까지의 시계열데이터가 다음과 같다.

시점 1-10: -1.356, -1.567, -0.994, -0.417, 0.840, -0.991, 0.166, 0.889, 0.514, -0.491

시점 11-20: -0.766, -1.936, -2.223, -1.395, -1.512, -0.582, 1.204, 1.706, -0.768, -0.313

- 과거데이터를 바탕으로 시계열모형은 다음의 AR(2)를 따르는 것으로 추정되었다.

$$Z_t = 0.7Z_{t-1} - 0.2Z_{t-2} + a_t (\sigma_a^2 = 1.0)$$

- 시점 10에서부터 한단계이후 예측치를 구하고 다음 시점의 실제값과 비교하여 예측오차를 산출하라.

(풀이) 한단계이후 예측치는 다음과 같다.

$$f_{n,1} = 0.7Z_n - 0.2Z_{n-1}$$

$$f_{11,1} = 0.7Z_{11} - 0.2Z_{10}$$

$$f_{11,1} = 0.7 \times (-0.766) - 0.2 \times (-0.491) = -0.438$$

n	$Z_n$	예측치	오차
10	-0.491	-	-
11	-0.766	-0.4465	-0.3195
12	-1.936	-0.4380	-1.4980
13	-2.223	-1.2020	-1.0210
14	-1.395	-1.1689	-0.2261
15	-1.512	-0.5319	-0.9801
16	-0.582	-0.7794	0.1974
17	1.204	-0.1050	1.3090
18	1.706	0.9592	0.7468
19	-0.768	0.9534	-1.7214
20	-0.313	-0.8788	0.5658

# 시계열 예측

## MA모형의 예측

- MA(2) 모형:  $Z_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2}$

- 한단계 예측식:  $f_{n,1} = E[Z_{n+1}|Z_n, Z_{n-1}, \dots] = -\theta_1 a_n - \theta_2 a_{n-1}$
- 2-단계 예측식:  $f_{n,2} = E[Z_{n+2}|Z_n, Z_{n-1}, \dots] = -\theta_2 a_n$
- 한단계 예측오차 분산:  $\text{Var}[e_{n,1}] = \sigma_a^2$
- 2-단계 예측오차 분산:  $\text{Var}[e_{n,2}] = \text{Var}[Z_{n+2}|Z_n, Z_{n-1}, \dots] = (1 + \theta_1^2)\sigma_a^2$

- MA(q) 모형:  $Z_t = a_t - \theta_1 a_{t-1} - \dots - \theta_q a_{t-q}$

- 한단계 예측식:  $f_{n,1} = E[Z_{n+1}|Z_n, Z_{n-1}, \dots] = -\theta_1 a_n - \theta_2 a_{n-1} - \dots - \theta_q a_{n+1-q}$
- 2-단계 예측식:  $f_{n,2} = E[Z_{n+2}|Z_n, Z_{n-1}, \dots] = -\theta_2 a_n - \theta_3 a_{n-1} - \dots - \theta_q a_{n+2-q}$
- 한단계 예측오차 분산:  $\text{Var}[e_{n,1}] = \sigma_a^2$
- 2-단계 예측오차 분산:  $\text{Var}[e_{n,2}] = \text{Var}[Z_{n+2}|Z_n, Z_{n-1}, \dots] = (1 + \theta_1^2)\sigma_a^2$
- 실제 예측치 산출을 위해서는 추정치 사용, 이 때  $a_n$ 의 추정치로는 해당 시점의 잔차를 사용

# ARMA모형 예측

(예- MA(2) 모형) 시점 1에서 20까지의 시계열데이터가 다음과 같다.

시점 1-10: 1.377, 1.856, -0.655, -0.587, -0.188, 1.414, 0.731, -1.628, -0.511, -0.294

시점 11-20: 0.499, -0.442, 1.019, -1.705, -0.139, 0.219, 1.131, -0.508, 0.541, -0.809

- 과거데이터를 바탕으로 시계열모형은 다음의 MA(2)를 따르는 것으로 추정되었다.

$$Z_t = a_t - 0.6a_{t-1} - 0.2a_{t-2} \quad (\sigma_a^2 = 1.0)$$

- 시점 11에서부터 한단계이후 예측치를 구하고 다음 시점의 실제값과 비교하여 예측오차를 산출하라.

(풀이) 한단계이후 예측치는 다음과 같다.

$$f_{n,1} = -0.6a_n - 0.2a_{n-1}$$

여기서  $a_t = (1 - 0.6B - 0.2B^2)^{-1} \approx (1 + 0.6B + 0.56B^2 + 0.456B^3 + 0.3856B^4)Z_t$

$$f_{11,1} = -0.6a_{11} - 0.2a_{10} = 0.38114$$

$$f_{12,1} = -0.6a_{12} - 0.2a_{11} = 0.7856$$


n	$Z_n$	$a_n$	예측치	오차
10	-0.294	-0.6337	-	-
11	0.499	-0.4240	0.4814	0.0176
12	-0.442	-1.1680	0.3812	-0.8232
13	1.019	0.7021	0.7856	0.2334
14	-1.705	-1.2269	-0.1877	-1.5173
15	-0.139	-0.6005	0.5957	-0.7347
16	0.219	-0.5250	0.6057	-0.3867
17	1.131	0.8000	0.4351	0.6959
18	-0.508	-0.4276	-0.3750	-0.1330
19	0.541	0.9158	0.0965	0.4444
20	-0.809	-0.1687	-0.4640	-0.3450

# 시계열 예측

$$ex) 357.5 + 0.439 \times 718 + 0.2064 \times 919 = 837.1818 \approx 837.2$$

- 예 (나일강 유량) 1872-1970년 사이 나일강 유량 시계열의 추정 모형은 AR(2)이며 추정식은 다음과 같다.
  - $\hat{Z}_t = 357.5 + 0.4039Z_{t-1} + 0.2064Z_{t-2}$ . 1967년 부터 5년간 한단계 예측값은 표와 같다.

Time Series Plot nile\_flow



년도	실제값	예측값	잔차
1967	919	847.0	72.0
1968	718	882.7	-164.7
1969	714	837.2	-123.2
1970	740	794.1	-54.1
1971	-	803.8	