

## 시계열 분석 기법과 응용

✓ 여러 경제, 금융 시계열을 동시에 분석

Week 6. 벡터자기회귀모형

- 2개의 주  
(분석) ① 정상적 시계열로 변환해 분석  
② 비정상적 시계열 자체로 분석

### 6-1. 벡터자기회귀모형의 식별 및 추정

전치혁 교수

(포항공과대학교 산업경영공학과)

# 벡터자기회귀모형

- 벡터 시계열

- 여러 시계열을 동시에 고려하여 상호 연관성을 분석

- 예 (3개의 시계열) → 어떤 상호 관계를 맺는지 분석해 정책 수립

시계열 1:  $Z_{1t}$  - 분기별 소비


시계열 2:  $Z_{2t}$  - 분기별 소득

시계열 3:  $Z_{3t}$  - 분기별 자산

- 벡터시계열의 표현:

$$\mathbf{z}_t = \begin{pmatrix} Z_{1t} \\ Z_{2t} \\ Z_{3t} \end{pmatrix}, t = 1, 2, \dots$$

- 벡터자기회귀 (vector autoregressive: VAR) 모형이 주로 사용



# 벡터자기회귀모형

- 벡터자기회귀 (VAR) 모형

- 한 시계열에 대한 AR(1) 모형

$$Z_t = \phi_1 Z_{t-1} + a_t$$

- **두** 시계열에 대한 VAR(1) 모형 → 과거 시점 하나만 영향, ∴ VAR(1)

$$\begin{cases} Z_{1t} = \phi_{11}Z_{1,t-1} + \phi_{12}Z_{2,t-1} + a_{1t} \\ Z_{2t} = \phi_{21}Z_{1,t-1} + \phi_{22}Z_{2,t-1} + a_{2t} \end{cases}$$

→  $Z_1, Z_2$ 의 과거값에 영향받음!

여기서  $a_{1t} \sim \text{Nor}(0, \sigma_1^2), a_{2t} \sim \text{Nor}(0, \sigma_2^2)$  이며,  $\text{Cov}[a_{1t}, a_{2t}] = \sigma_{12} \Rightarrow$  (벡터로 표현)

$$z_t = \begin{pmatrix} Z_{1t} \\ Z_{2t} \end{pmatrix}, a_t = \begin{pmatrix} a_{1t} \\ a_{2t} \end{pmatrix}, \Phi_1 = \begin{bmatrix} \phi_{11} & \phi_{12} \\ \phi_{21} & \phi_{22} \end{bmatrix}$$

↑ white noise      ↑ 계속 → 상관관계

$$z_t = \Phi_1 z_{t-1} + a_t, a_t \sim \text{MVN}(\mathbf{0}, \Sigma), \Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix}$$

↳ AR(1) 꼴  
but  $\Phi_1$  : matrix  
 $z_{t-1}, a_t$  : vector      ↳ multivariate normal (vectors)

# VAR 모형

- $m$ 차원 시계열의 VAR(1) 모형

$$\mathbf{z}_t = \begin{pmatrix} Z_{1t} \\ \vdots \\ Z_{mt} \end{pmatrix}; \mathbf{z}_t = \underbrace{\Phi_1 \mathbf{z}_{t-1} + \mathbf{a}_t}_{\text{AR(1) 뿐 but vector}} \quad (\text{여기서 } \Phi_1 \text{는 } m \times m \text{ 행렬})$$

- $m$ 차원 시계열의 VAR( $p$ ) 모형

$$\mathbf{z}_t = \Phi_1 \mathbf{z}_{t-1} + \Phi_2 \mathbf{z}_{t-2} + \dots + \Phi_p \mathbf{z}_{t-p} + \mathbf{a}_t$$

$$\Phi(x) = I - \Phi_1 x - \dots - \Phi_p x^p \Rightarrow \Phi(B) \mathbf{z}_t = \mathbf{a}_t$$

VAR(1)형태의 표현  $\rightarrow$  VAR( $p$ )보다 VAR(1)모형이 성질 찾기 쉬우므로 변환해줌

$$\mathbf{y}_t = \begin{pmatrix} \mathbf{z}_t \\ \mathbf{z}_{t-1} \\ \vdots \\ \mathbf{z}_{t-p+1} \end{pmatrix}, F = \begin{bmatrix} \Phi_1 & \Phi_2 & \dots & \Phi_p \\ I & 0 & & 0 \\ & \ddots & & \\ 0 & & I & 0 \end{bmatrix}, \mathbf{v}_t = \begin{pmatrix} \mathbf{a}_t \\ 0 \\ \vdots \\ 0 \end{pmatrix} \Rightarrow \mathbf{y}_t = F \mathbf{y}_{t-1} + \mathbf{v}_t$$

# VAR 모형

- 정상성 조건

## VAR(1)모형의 정상성 조건

- 모형:  $\mathbf{z}_t = \Phi_1 \mathbf{z}_{t-1} + \mathbf{a}_t$
- 계수행렬  $\Phi_1$ 의 고유치들의 크기가 모두 1보다 작아야 한다.
- $\det \Phi(x) = \det(I - \Phi_1 x) = 0$ 의 근들의 크기가 모두 1보다 커야 한다.

## VAR(p)모형의 정상성 조건

- 모형:  $\mathbf{z}_t = \Phi_1 \mathbf{z}_{t-1} + \Phi_2 \mathbf{z}_{t-2} + \dots + \Phi_p \mathbf{z}_{t-p} + \mathbf{a}_t$   
 $\Phi(B)\mathbf{z}_t = \mathbf{a}_t, \Phi(x) = I - \Phi_1 x - \dots - \Phi_p x^p$
- $\det \Phi(x) = \det(I - \Phi_1 x - \dots - \Phi_p x^p) = 0$ 의 근들의 크기가 모두 1보다 커야 한다.
- $\mathbf{y}_t = F\mathbf{y}_{t-1} + \mathbf{v}_t$ 의 형태에서 행렬 F의 고유치들의 크기가 모두 1보다 작아야 한다.

# VAR 모형

- 정상성 조건

(예) 다음의 두 시계열에 대한 VAR(2)모형이 정상적인지 알아보자.

$$\begin{pmatrix} Z_{1t} \\ Z_{2t} \end{pmatrix} = \begin{bmatrix} 0.3 & -0.1 \\ -0.05 & 0.25 \end{bmatrix} \begin{pmatrix} Z_{1,t-1} \\ Z_{2,t-1} \end{pmatrix} + \begin{bmatrix} 0.2 & -0.75 \\ -0.1 & 0.4 \end{bmatrix} \begin{pmatrix} Z_{1,t-2} \\ Z_{2,t-2} \end{pmatrix} + \begin{pmatrix} a_{1t} \\ a_{2t} \end{pmatrix}, \quad \Sigma = \begin{bmatrix} 0.6 & 0.05 \\ 0.05 & 1 \end{bmatrix}$$

$\overset{\sim \text{Var}(a_{1t})}{0.6} \quad \overset{\sim \text{Cov}(a_{1t}, a_{2t})}{0.05}$   
 $\quad \quad \quad \underset{\sim \text{Var}(a_{2t})}{1}$

(풀이)  $y_t = Fy_{t-1} + v_t$  형태로 표시하면 행렬 F는 다음과 같다.

$$F = \begin{bmatrix} 0.3 & -0.1 & 0.2 & -0.75 \\ -0.05 & 0.25 & -0.1 & 0.4 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix}$$

- 고유치는 다음과 같다.  $\lambda_1 = 0.9627, \lambda_2 = 0.2376, \lambda_3 = -0.0356, \lambda_4 = -0.6148$
- 즉, 고유치 크기가 모두 1보다 작으므로 위의 VAR(2)모형은 정상적이다.

# VAR 모형

- 모형의 식별 - 시차  $p$  결정

방법 1: 이론적 ACF/PACF를 구하고 표본 ACF/PACF와 비교 → VAR에서 구하기 어려움

- 교차상관관계 등이 존재하므로 쉽지 않음
- 개별 시계열에 대한 표본 ACF/PACF를 관찰하고 충분한 시차  $p$ 를 추정할 수도 있음

방법 2: 정보기준 (information criteria) 사용

- 실제로 널리 사용되고 있음 likelihood function, # (parameter)로 표현
- 여러 시차에 대해 AIC, BIC, HQ 등을 산출하고 정보기준값이 최소인 시차 선택

- $AIC(p) = \ln|\hat{\Sigma}| + \frac{2m^2p}{N}$  : Akaike information criteria

- $BIC(p) = \ln|\hat{\Sigma}| + \frac{m^2p \ln N}{N}$  : Schwarz (Bayesian) information criteria

- $HQ(p) = \ln|\hat{\Sigma}| + \frac{2m^2p \ln \ln N}{N}$  : Hannan -Quinn information criteria

방법 3: 우도비 검정

# VAR 모형의 식별

(예) 다음은 세가지 벡터 시계열에 대한 여러 시차에 따른 VAR모형을 추정한 후 정보기준값을 산출한 결과이다.

적절한 시차  $p$ 를 선택하라.

- SC 기준으로는 시차 1이 가장 적절하다고 볼 수 있으나 대부분 기준은 시차 2가 적절하다고 선언하므로 결과적으로 시차 2가 최적이라 하겠다.
- 기준마다 서로 다른 최적 시차를 제시하는 경우에는 가장 작은 시차를 최종적으로 선택하는 것도 방법이라 하겠다.  
가장 작은 시차

Lag	LogL	LR	FPE	AIC	SC	HQ
0	-1415.48	NA	5.05e+11	35.46	35.55	35.49
1	-1070.11	656.19	1.13e+08	27.05	27.41*	27.19
2	-1055.28	27.07*	9.74e+07*	26.90*	27.53	27.16*
3	-1046.40	15.53	9.79e+07	26.91	27.80	27.27
4	-1039.98	10.75	1.05e+08	26.97	28.14	27.44
5	-1038.50	2.37	1.28e+08	27.16	28.59	27.73

LR: sequential modified LR test statistic (each test at 5% level)

FPE: final prediction error





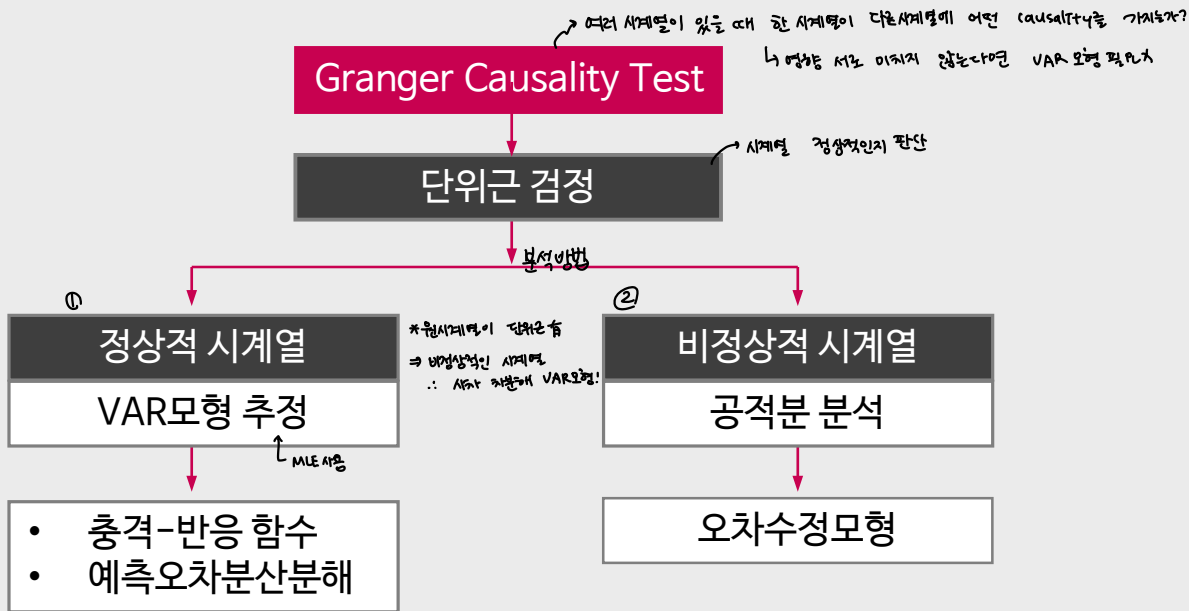
## 시계열 분석 기법과 응용

Week 6. 벡터자기회귀모형

6-2. 충격-반응 함수와 분산분해

전치혁 교수  
(포항공과대학교 산업경영공학과)

# VAR모형 분석



# 그레인저 인과관계

~  $X, Y$ : 두 시계열

(그레인저 인과관계: Granger causality) 시계열  $\{X_t, t \geq 1\}$ 이 시계열  $\{Y_t, t \geq 1\}$ 의 미래값을 예측하는 데 도움이 될 때,  $\{X_t, t \geq 1\}$ 이  $\{Y_t, t \geq 1\}$ 에 영향을 준다 (Granger-cause) 말한다.

↳ granger causal relationship: 반드시 대립적인 것은 아님

그레인저 인과관계 검정 (가설검정)

- 자기회귀 시차모형

$$Y_t = \alpha_0 + \alpha_1 Y_{t-1} + \dots + \alpha_p Y_{t-p} + \beta_1 X_{t-1} + \dots + \beta_q X_{t-q} + a_t$$

~  $X$ 의 과거값에 영향받음

- 가설

$$H_0: \beta_1 = \dots = \beta_q = 0$$

~  $\beta=0$  일때  $Y$ 가  $X$ 에 대한 영향 받지 않는 것

- 검정통계량

$$F = \frac{(SSE_r - SSE_{ur})/q}{SSE_{ur}/(N-p-q-1)}$$

이 모형의 SSE

이때의 SSE

여기서  $SSE_{ur}$  는 상기 모형 (비제한모형)의 SSE이며,  $SSE_r$  는  $H_0$ 가 옳을 때 (제한모형) SSE임

- 결과 해석 : 쌍방에 대해 검정. 서로 영향을 주지않을 때는 VAR모형 분석의 의미가 없음.

~  $X \rightarrow Y$  or  $Y \rightarrow X$

# 그레인저 인과관계

(예 6-1) 영국 소비(LC)/소득(LI)/자산(LW) 데이터에 대한 그레인저 인과관계 검정을 실시하면 아래와 같다.

EViews software


Pairwise Granger Causality Tests

Date: 07/19/19 Time: 11:13

Sample: 1966Q4 1991Q2

Lags: 4

Null Hypothesis:	Obs	F-Statistic	Prob.
LI does not Granger Cause LC → LI가 LC에 영향 X	95	1.77913	0.1404 → don't reject H <sub>0</sub>
LC does not Granger Cause LI		8.15510	1.E-05 → reject H <sub>0</sub>
LW does not Granger Cause LC	95	2.25700	0.0695 → 4% level
LC does not Granger Cause LW		0.72713	0.5758
LW does not Granger Cause LI	95	1.34091	0.2614
LI does not Granger Cause LW		0.52232	0.7196



결과해석: 소비가 소득에 유의하게 영향을 미침, 유의수준 10%에서 자산이 소비에 영향을 미침

# 충격-반응 함수

## 충격-반응 함수 (impulse-response function; IRF)

한 시계열에 특정시점에서 충격이 발생할 때 다른 시계열에 시간에 따라 어떤 영향을 주는지 분석

ex) 달러환율 상승  
→ 유로, 엔가와 환율, GDP, ... 영향?  
분석

### • VAR(1) 모형 예

$$Z_{1t} = \phi_{11}Z_{1,t-1} + \phi_{12}Z_{2,t-1} + a_{1t}$$

$$Z_{2t} = \phi_{21}Z_{1,t-1} + \phi_{22}Z_{2,t-1} + a_{2t}$$

충격: 시점 1에서  $Z_{1t}$ 에만  $\sigma_1$ 의 충격이 있고  $Z_{2t}$ 에는 충격이 없음. 다른 시점에는 충격 없음

( $a_{11} = \sigma_1, a_{1t} = 0, t > 1, a_{2t} = 0, t \geq 1; Z_{10} = Z_{20} = 0$  가정)

반응

t=1:  $Z_{11} = a_{11} = \sigma_1; Z_{21} = a_{21} = 0$  ↖ 2.에만 충격 but  $Z_{2t}$  변화

t=2:  $Z_{12} = \phi_{11}Z_{11} + \phi_{12}Z_{21} + a_{12} = \phi_{11}\sigma_1; Z_{22} = \phi_{21}Z_{11} + \phi_{22}Z_{21} + a_{22} = \phi_{21}\sigma_1$

t=3:  $Z_{13} = \phi_{11}Z_{12} + \phi_{12}Z_{22} + a_{13} = (\phi_{11}^2 + \phi_{12}\phi_{21})\sigma_1$

$$Z_{23} = \phi_{21}Z_{12} + \phi_{22}Z_{22} + a_{23} = (\phi_{21}\phi_{11} + \phi_{22}\phi_{21})\sigma_1$$

- 반응함수: 시간에 따른  $Z_{1t}$ 에의 영향, 시간에 따른  $Z_{2t}$ 에의 영향

t=1에서만 충격  
but  
t=2,3에서도  
 $Z_{1t}, Z_{2t}$  변화.

# 충격-반응 함수

## VAR 모형

$$\mathbf{z}_t = \Phi_1 \mathbf{z}_{t-1} + \Phi_2 \mathbf{z}_{t-2} + \cdots + \Phi_p \mathbf{z}_{t-p} + \mathbf{a}_t$$

## MA형태 모형

$$\mathbf{z}_t = \mathbf{a}_t + \Psi_1 \mathbf{a}_{t-1} + \Psi_2 \mathbf{a}_{t-2} + \cdots$$

## 직교오차 MA형태 모형

$$\mathbf{z}_t = \mathbf{v}_t + \Psi_1 \mathbf{v}_{t-1} + \Psi_2 \mathbf{v}_{t-2} + \cdots$$

$IRF(i, j, s)$

=  $j$ 번째 시계열의 충격에 대한  $i$ 번째 시계열의 시간  $s$ 이후의 반응

=  $\Psi_s^*$ 의  $(i, j)$ 원소

시계열간의 상관관계가 있어  
IRF산출 어려움  $\sim$  2간 상관관계  
 $\therefore$  MA형태  $\rightarrow$  white noise 독립  $\therefore$  분석용이

MA꼴

$\mathbf{a}_t \sim MVN(0, \Sigma)$  이므로 여전히  
오차항간의 상관관계가 있어  
IRF산출 어려움

직교오차 MA꼴!  
 $\rightarrow$  white noise간 공존성이 없음

$\mathbf{v}_t \sim MVN(0, I)$  이므로  
IRF산출 용이

# 충격-반응 함수

- MA형태 모형

$$\mathbf{z}_t = \mathbf{a}_t + \Psi_1 \mathbf{a}_{t-1} + \Psi_2 \mathbf{a}_{t-2} + \dots, \mathbf{a}_t \sim MVN(0, \Sigma)$$

- $\Sigma$ 의 분해 → 적교오차 MA형태 변환 위해 소분해 필요!

- LDL 분해: positive definite 대칭행렬 분해

$$\Sigma = LDL^T \quad (L: \text{대각원소가 1인 아래쪽 삼각행렬}; D: \text{양의 원소를 갖는 대각행렬})$$

- Cholesky 분해: 양의 대각원소를 갖는 삼각행렬로 분해

$$\Sigma = PP^T \quad (P = LD^{1/2})$$

- 직교오차 변환

$$\begin{aligned} \mathbf{v}_t &= P^{-1} \mathbf{a}_t \\ \text{Var}[\mathbf{v}_t] &= \text{Var}[P^{-1} \mathbf{a}_t] = P^{-1} \Sigma (P^{-1})^T = I \end{aligned}$$

- 직교오차 MA형태 모형

$$\mathbf{z}_t = \mathbf{v}_t + \Psi_1^* \mathbf{v}_{t-1} + \Psi_2^* \mathbf{v}_{t-2} + \dots$$

# 충격-반응 함수


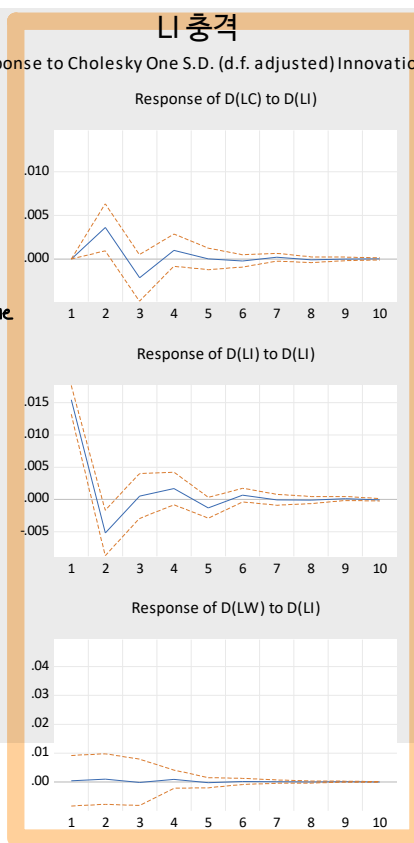

→ 연관성이 많은 시계열일수록 충격에 민감하게 반응

(예 6-2) 영국 소비/소득/자산 1차 차분 데이터에 대한 충격-반응 함수 도출

LC 반응

LI 반응

LW 반응





# 예측오차 분산분해

## • 필요성

- 특정 시계열의 미래 불확실성에 다른 여러 시계열의 충격이 영향을 줄 수 있음

이때 어떤 시계열이 상대적으로 어떤 영향을 끼치고 있는지 중요도 산출이 의미있음 즉, 미래 불확실성에 대해 시계열이 상대적으로 얼마나 중요한가?

- 이를 위해 미래값을 예측하고 예측오차의 분산을 시계열별로 분해함

## • 예측오차

- 모형:  $\mathbf{z}_t = \mathbf{v}_t + \Psi_1^* \mathbf{v}_{t-1} + \Psi_2^* \mathbf{v}_{t-2} + \dots$

- k-단계 예측치 (예측)

$$\mathbf{f}_{t,k} = E[\mathbf{z}_{t+k} | \mathbf{z}_t, \dots] = \Psi_k^* \mathbf{v}_t + \Psi_{k+1}^* \mathbf{v}_{t-1} + \dots$$

- k-단계 예측오차 (계산)

$$\mathbf{e}_{t,k} = \mathbf{v}_{t+k} + \Psi_1^* \mathbf{v}_{t+k-1} + \Psi_2^* \mathbf{v}_{t+k-2} + \dots + \Psi_{k-1}^* \mathbf{v}_{t+1}$$

- i-번째 시계열의 k-단계 예측오차

$$e_{t,k}^{(i)} = \sum_{j=1}^m v_{j,t+k} + \sum_{j=1}^m \psi_{ij,1}^* v_{j,t+k-1} + \dots + \sum_{j=1}^m \psi_{ij,k-1}^* v_{j,t+1}$$

이 예측오차의 분산을 분해!

# 예측오차 분산분해

- 예측오차 분산분해 (variance decomposition)

① i-번째 시계열의 k-단계 예측오차 계산

$$e_{t,k}^{(i)} = \sum_{j=1}^m v_{j,t+k} + \sum_{j=1}^m \psi_{ij,1}^* v_{j,t+k-1} + \dots + \sum_{j=1}^m \psi_{ij,k-1}^* v_{j,t+1}$$

② i-번째 시계열의 k-단계 예측오차 분산 계산 → 각 시계열의 비중 계산

$$Var[e_{t,k}^{(i)}] = m + \sum_{j=1}^m (\psi_{ij,1}^*)^2 + \dots + \sum_{j=1}^m (\psi_{ij,k-1}^*)^2 = \sum_{s=0}^{k-1} \sum_{j=1}^m (\psi_{ij,s}^*)^2$$

이중 j-번째 시계열 분산 비중

$$Var[e_{t,k}^{(ij)}] = 1 + (\psi_{ij,1}^*)^2 + \dots + (\psi_{ij,k-1}^*)^2 = \sum_{s=0}^{k-1} (\psi_{ij,s}^*)^2$$

③ i-번째 예측오차분산 중 j-번째 시계열 기여율

↳ 상대적 기여율 분석 → 어느 시계열이 중요한지 파악

$$R_{ij,k} = \frac{Var[e_{t,k}^{(ij)}]}{Var[e_{t,k}^{(i)}]} \times 100 = \frac{\sum_{s=0}^{k-1} (\psi_{ij,s}^*)^2}{\sum_{s=0}^{k-1} \sum_{j=1}^m (\psi_{ij,s}^*)^2} \times 100(\%)$$

↑

i-번째 시계열의  
k-단계 예측오차분산에 대한  
j-번째 시계열의 기여도

↑

percentage  
단위

# 예측오차 분산분해

(예 6-3) 영국 소비/소득/자산 데이터에 대한 예측오차 분산분해

Variance Decomposition of D(LC):		차분항등		
Period	S.E.	D(LC)	D(LI)	D(LW)
		→ 비체계적 변동성		
		→ 처음에 LC가 100%이며		
1	0.012824	100.0000	0.000000	0.000000
2	0.013775	87.97436	6.915991	5.109644
3	0.014178	84.78336	8.791400	6.425242
4	0.014230	84.26114	9.232929	6.505934
5	0.014244	84.12672	9.215815	6.657461
6	0.014251	84.11612	9.230617	6.653260
7	0.014253	84.09334	9.250909	6.655749
8	0.014253	84.08904	9.253813	6.657074
9	0.014253	84.08914	9.253787	6.657074
10	0.014253	84.08885	9.253944	6.657206

이러시행

상대적 중요도 다른 시계열에서 증감 (LC 제외)  
→ 어느정도 증가 이후 안정하게 유지  
↳ 분석을 통해 작게 시계열의 다른 시계열이 얼마나 큰 영향, 즉, 상대적 중요성분수 있음

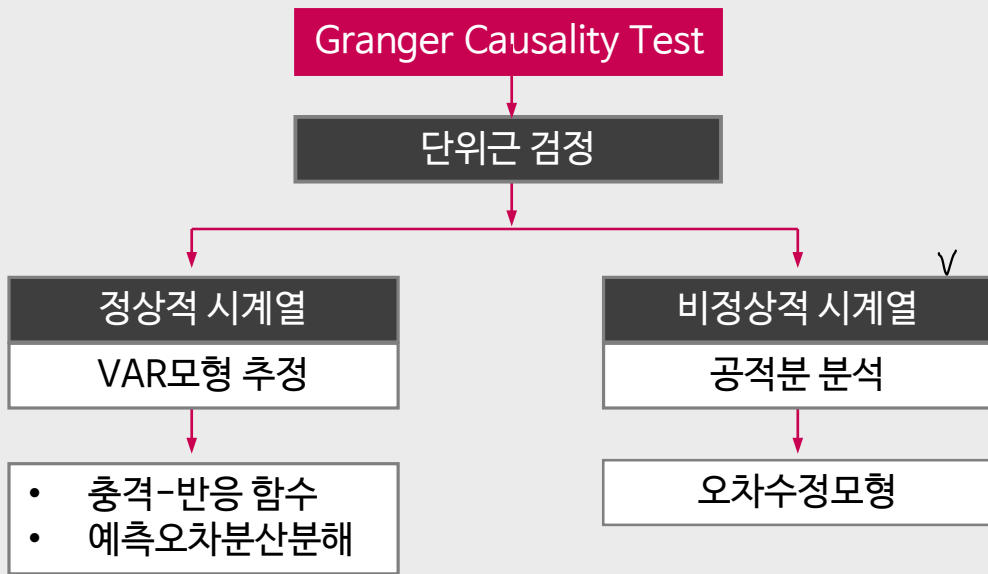


## 시계열 분석 기법과 응용

### Week 6. 벡터자기회귀모형 6-3. 공적분과 오차수정 모형

전치혁 교수  
(포항공과대학교 산업경영공학과)

# VAR모형 분석



# 비정상적 시계열 분석

## 필요성

- VAR모형은 정상적 시계열에 대하여 적용
  - 비정상적 시계열에 대해서는 차분을 통해 정상성 확보후에 VAR모형화
- 경제/금융관련 시계열들에 각각은 비정상적이나 장기적으로 균형적 관계를 갖는 경우가 있으며 이를 공적분 (cointegration) 관계라 함. (예) 소득과 소비 : 연도별 소득 증가 → 소비도 이에 따라 증가  
~ 소득, 재정성, 사회적 존재
- 이런 경우 각각을 차분하여 정상적 시계열로 변환하여 분석하는 것보다 직접적으로 회귀 모형화하는 것이 보다 많은 정보를 얻음. → 비정상적 시계열 직접적 분석이래
- 공적분관계가 없는 비정상적 시계열을 대상으로 회귀분석할 때 가성 회귀 (spurious regression)의 문제가 발생함에 유의  
↗ 완벽함의 두 시계열이 증가한다는 가정 하 회귀분석  
결과로 나오는 상관관계는 가짜임!
- 공적분 분석을 위해서는 각 시계열이 동일 차수의 (비정상적) 누적 시계열이어야 함.

\* 원시제곱  $\gamma_n$ : 비정상적  $\rightarrow$  1차 차분  $\rightarrow (1-\beta)\gamma_n$ ; 비정상적?  $\rightarrow$  2차 차분  $\rightarrow (1-\beta)^2\gamma_n$ : 정상적  $\Rightarrow$  원시제곱  $\gamma_n$ : 차수 2의 주파수 벡터시제곱 =  $I(2)$

- 벡터 시계열  $\{x_t, t \geq 1\}$ 에 대해  $\{(1 - B)^{d-1}x_t, t \geq 1\}$ 는 비정상적이거나  $\{(1 - B)^d x_t, t \geq 1\}$ 이 정상적일 때, 차수  $d$ 의 누적 벡터시계열이라 하며  $\{x_t, t \geq 1\} \sim I(d)$ 로 표기

ex) 2차 부정행렬사제면  $I(2) \rightarrow$  선형변환을 통해 정상적 사제됨이 될때 "공적분관계"

- $I(d)$  인 누적 벡터시계열에 대해 선형결합  $\alpha^T x_t$ 이 차수  $d$  미만의 누적 시계열이 될 때, 공적분 벡터  $\alpha$ 를 갖는 공적분 관계에 있다 함  
↳ 즉, 선형 결합으로 차수 적어지는 경우 (d=1, 즉 0차 누적 벡터시계열 : 정상적 시계열)
- 총 m개의 시계열이 있을 때 최대 m-1개의 공적분 벡터가 있을 수 있음. 이 때 존재하는 공적분 벡터의 최대수를 공적분 랭크 (cointegration rank)라 함
- (예) 다음 세 시계열을 고려하자.

-  $Z_{1t} = Z_{1,t-1} + a_{1t}$ ;  $Z_{2t} = \beta_1 Z_{1t} + a_{2t}$ ;  $Z_{3t} = \beta_2 Z_{1t} + \beta_3 Z_{2t} + a_{3t}$   
 - 가시계역은  $I(1)$

- 각 시계열은  $I(1)$

$$-\beta_1 Z_{1,t} + Z_{2,t} + 0Z_{3,t} = a_{2t} \sim I(0); \quad -\beta_2 Z_{1,t} - \beta_3 Z_{2,t} + Z_{3,t} = a_{3t} \sim I(0)$$

- 따라서 공적분 랭크는 2

2개의 공저분 vector!

# 오차수정모형

## 필요성

- 여러 시계열이 공적분 관계가 있는 경우 오차수정모형 (error correction model; ECM)을 통하여 시계열 상호간의 미치는 단기 및 장기 효과를 분석할 수 있음.
- 공적분 관계는 ECM 표현을 위한 필요충분조건임 (그레인저 표현정리-Engle and Granger, 1987).

단기 동적분 관계 있음  $\longleftrightarrow$  ECM 표현 가능

## ECM 유도 예

- 두 시계열  $\{X_t\}$ 와  $\{Y_t\}$ 가 각각  $I(1)$ 이며 다음의 공적분 관계가 있다고 하자.

$$Y_t = \beta X_t + \varepsilon_t$$

- 이 관계식을 다음과 같이 쓸수있다.

$$\begin{aligned}
 Y_t - (Y_{t-1} - Y_{t-1}) &= \beta X_t + \beta(X_{t-1} - X_{t-1}) + \varepsilon_t \quad \begin{matrix} \swarrow Y_{t-1} \text{ 빼고 더함} & \searrow X_{t-1} \text{ 빼고 더함} \end{matrix} \\
 \Downarrow \quad \textcircled{e_{t-1}} &= Y_{t-1} - \beta X_{t-1} \quad \begin{matrix} \swarrow \text{시계열} & \searrow \text{예측값} \end{matrix} \quad (\text{이전 시점 오차}) \\
 \Delta Y_t &= -e_{t-1} + \beta \Delta X_t + \varepsilon_t
 \end{aligned}$$

$$\rightarrow Y_t - Y_{t-1} = \beta X_t + \beta X_{t-1} - \beta X_{t-1} + \varepsilon_t - Y_{t-1}$$

$$\Delta Y_t = -e_{t-1} + \beta X_t - \beta X_{t-1} + \varepsilon_t$$

$$\Delta Y_t = -e_{t-1} + \beta \Delta X_t + \varepsilon_t$$

↑  
Y가 변함 → 이전 시점 오차와 X의 차분으로 표현됨  
⇒ ECM의 가장 기본적인 형태



# 오차수정모형

## • 단순형태 ECM

$$\Delta Y_t = \lambda e_{t-1} + \beta \Delta X_t + \varepsilon_t$$

↙ 항상 음수

- $\lambda e_{t-1}$  ( $\lambda < 0$ ): 오차수정항 (error correction term) - 이전 시점에서 예측오차가 양수이면 (실제값이 예측값보다 크면) 다음 시점에서 Y값을 축소시켜 X와 Y의 장기적관계를 유지시키는 효과 → X, Y 관계식이 유지되도록 오차 커지면 Y값 축소 ??? 작아지면 " 증가 ...
- X값에 변화가 있으면 Y값에 영향을 줌 (단기 효과)

↳  $\Delta X$ 가  $\Delta Y$ 에 영향

## • 시차변수를 포함한 ECM

$$\Delta Y_t = \lambda e_{t-1} + \sum_{j=1}^p \beta_{1j} \Delta X_{t-j} + \sum_{j=1}^p \gamma_{1j} \Delta Y_{t-j} + \varepsilon_{1t} \quad (e_{t-1} = Y_{t-1} - \beta X_{t-1})$$

$$\Delta X_t = \lambda e_{t-1} + \sum_{j=1}^p \beta_{2j} \Delta X_{t-j} + \sum_{j=1}^p \gamma_{2j} \Delta Y_{t-j} + \varepsilon_{2t}$$

:  $\Delta X$ 과  $\Delta Y$ 가 어떤 변화량으로 표현 가능  
∴ X, Y 동시에 표현하는 벡터에 대해 ECM 모델

$$\Rightarrow \begin{pmatrix} \Delta X_t \\ \Delta Y_t \end{pmatrix} = \begin{bmatrix} -\lambda\beta & \lambda \\ -\lambda\beta & \lambda \end{bmatrix} \begin{pmatrix} X_{t-1} \\ Y_{t-1} \end{pmatrix} + \sum_{j=1}^p \begin{bmatrix} \beta_{2j} & \gamma_{2j} \\ \beta_{1j} & \gamma_{1j} \end{bmatrix} \begin{pmatrix} \Delta X_{t-j} \\ \Delta Y_{t-j} \end{pmatrix} + \begin{pmatrix} \varepsilon_{2t} \\ \varepsilon_{1t} \end{pmatrix}$$

# 오차수정모형

- VAR모형과 벡터 ECM (VECM)

- 벡터 시계열의 경우 공적분관계가 있을 때 벡터 ECM (VECM)으로 확장됨
- $I(1)$ 인 VAR(p)모형은 공적분관계 여부와 관계없이 다음의 VECM으로 표현

$$\mathbf{z}_t = \Phi_1 \mathbf{z}_{t-1} + \Phi_2 \mathbf{z}_{t-2} + \cdots + \Phi_p \mathbf{z}_{t-p} + \mathbf{a}_t$$

$$\Downarrow \quad \Pi = \Phi_1 + \Phi_2 + \cdots + \Phi_p - I, \quad \Gamma_k = -\sum_{j=k+1}^p \Phi_j$$

$$\Delta \mathbf{z}_t = \Pi \mathbf{z}_{t-1} + \sum_{j=1}^{p-1} \overset{\sim \text{타이머}}{\Gamma_j} \overset{\uparrow \text{vector 자료}}{\Delta \mathbf{z}_{t-j}} + \mathbf{a}_t$$

- 행렬  $\Pi$  ( $m \times m$ )의 랭크 크기에 따라 3가지 경우

①  $\Pi = 0$ 인 경우: 공적분 관계 없으며 차분 형태가 정상적인 VAR(p-1)모형으로 변환

②  $\Pi$ 의 랭크가  $m$ 인 경우: VAR(p)모형이 이미 정상적

③  $\Pi$ 의 랭크가 0과  $m$  사이인 경우: 실제적 VECM. 공적분 관계식이 랭크수만큼 있음. 이 때  $\Pi = AB^T$ 가 성립하며 행렬  $B$ 의 열들이 공적분 벡터들이 됨. ↖ 벡터 변환 해설

# 공적분 검정

필요

(공적분관계 있는가?)

## Engle-Granger 검정

- 회귀분석의 잔차 시계열에 대하여 ADF검정 실시
- 단위근이 없다면 공적분 관계있다고 결론

## Johansen 검정

→ 주로 사용, 공적분 rank가 몇 개인가

- 트레이스 검정
  - $H_0: r = r_0$  VS  $H_1: r > r_0$
  - $r_0 = 0$ 에서 귀무가설 기각되면 다음으로  $r_0 = 1$ 을 검정하는 과정을 반복
  - 검정통계량은 우도비에 바탕으로 산출
- 최대고유치 검정
  - $H_0: r = r_0$  VS  $H_1: r = r_0 + 1$
  - 역시  $r_0 = 0, 1, \dots$  등으로 변화시키면서 순차적으로 진행

# 공적분과 오차수정모형 예

(예 6-4) 옆의 그림은 2016.1 ~ 2018.12 사이 kosp200과 kosp200 선물 지수를 나타낸다.  
다음을 알아보자

1. 공적분 검정
2. 공적분 관계
3. 오차수정모형



# 공적분과 오차수정모형 예

(예 6-4 계속)

다음은 공적분 검정 결과이다.

- 트레이스 검정 과 최대고유치 검정에  
서 두 시계열간 공적분관계가 있다고  
판정됨

Sample (adjusted): 1/11/2016 12/28/2018  
Included observations: 728 after adjustments  
Trend assumption: Linear deterministic trend  
Series: KOSPI200 KOSPI200\_FUTURE  
Lags interval (in first differences): 1 to 4

## Unrestricted Cointegration Rank Test (Trace)

Hypothesized No. of CE(s)	Eigenvalue	Trace Statistic	0.05 Critical Value	Prob.**
None *	0.051946	41.25473	15.49471	0.0000
At most 1	0.003319	2.420325	3.841466	0.1198

Trace test indicates 1 cointegrating eqn(s) at the 0.05 level

\*denotes rejection of the hypothesis at the 0.05 level

\*\*MacKinnon-Haug-Michelis (1999) p-values

## Unrestricted Cointegration Rank Test (Maximum Eigenvalue)

Hypothesized No. of CE(s)	Eigenvalue	Max-Eigen Statistic	0.05 Critical Value	Prob.**
None*	0.051946	38.83440	14.26460	0.0000
At most 1	0.003319	2.420325	3.841466	0.1198

Max-eigenvalue test indicates 1 cointegrating eqn(s) at the 0.05 level

\*denotes rejection of the hypothesis at the 0.05 level

\*\*MacKinnon-Haug-Michelis (1999) p-values

# 공적분과 오차수정모형 예

(예 6-4계속) 공적분관계식과 오차수정모형의 추정식을 보여준다.

공적분 관계식

$$k200_{t-1} = 0.2155 + \underbrace{0.9982}_{\text{계수} \approx 1} k200_{f_{t-1}}$$

오차수정모형

$$\begin{aligned} \Delta k200_t &= 0.0364 - \underbrace{0.1183}_{\text{계수 : 오차 발생 시 얼마나 빨리 조정되는가}} e_{t-1} - 0.1867 \Delta k200_{t-1} - 0.0136 \Delta k200_{t-2} \\ &\quad + 0.1561 \Delta k200_{f_{t-1}} + 0.0814 \Delta k200_{f_{t-2}} \\ \Delta k200_{f_t} &= 0.0365 + 0.0622 e_{t-1} + 0.0811 \Delta k200_{t-1} + 0.045 \Delta k200_{t-2} \\ &\quad - 0.1402 \Delta k200_{f_{t-1}} - 0.0133 \Delta k200_{f_{t-2}} \end{aligned}$$

마지막 주차정리

Cointegrating Eq:	CointEq1	
KOSPI200(-1)	1.000000	
KOSPI200_FUTURE(-1)	0.998212 (0.00329) [-303.412] -0.215456	주요됨
C		
Error Correction:	D(KOSPI200)	D(KOSPI200...
CointEq1	-0.118302 (0.12215) [-0.96850]	0.062194 (0.12706) [0.48949]
D(KOSPI200(-1))	-0.186666 (0.18259) [-1.02233]	0.081089 (0.18993) [0.42695]
D(KOSPI200(-2))	-0.013611 (0.17574) [-0.07745]	0.045013 (0.18280) [0.24624]
D(KOSPI200_FUTURE(..	0.156070 (0.17797) [0.87693]	-0.140201 (0.18512) [-0.75734]
D(KOSPI200_FUTURE(..	0.081424 (0.17234) [0.47245]	0.013280 (0.17927) [0.07408]
C	0.036415 (0.08482) [0.42932]	0.036494 (0.08823) [0.41363]

# VAR모형 분석

