

## WEEK 7. 상태공간모형

### 7-1. 상태공간모형의 표현

- 관측되는 변수와 관측되지 않는 변수를 구분함
- 사건에 따라 변하는 관측되지 않는 변수를 상태변수라 함
- 관측방정식, 상태방정식으로 구성됨
- 회귀, ARMA를 포함하는 광범위한 모형임

#### 모형의 표현

- (예 1) 시간  $t$  관측치를  $Y_t$  라 할 때 이는 상태변수  $\mu_t$  와 관측오차  $w_t$  로 부터 얻어지고 상태변수는 이전 시간의 상태와 오차  $v_t$  가 더해져 변한다고 하자. 이 때, 상태공간모형은 다음으로 표현된다.
  - (관측방정식)  $Y_t = \mu_t + w_t$
  - (상태방정식)  $\mu_t = \mu_{t-1} + v_t$
  - 오차항 가정:  $w_t \sim \text{Nor}(0, \sigma_w^2)$ ,  $v_t \sim \text{Nor}(0, \sigma_v^2)$  이며 다른 변수와 독립 → 상태변수
- (예 2) 시간  $t$  관측치를  $Y_t$  라 할 때 이는 수준 (level) 변수  $\mu_t$  와 관측오차  $\varepsilon_t$  로 부터 얻어진다. 수준변수는 이전 시간의 수준, 추세(trend)와 오차  $a_t$  가 더해져 변하고, 추세는 이전 추세와 오차  $b_t$  가 더해져 변한다고 하자. 이 때, 상태공간모형은 다음으로 표현된다.
  - (관측방정식)  $Y_t = \mu_t + \varepsilon_t$
  - (상태방정식)  $\mu_t = \mu_{t-1} + \beta_{t-1} + a_t$ ,  $\beta_t = \beta_{t-1} + b_t$
  - ⇒ 상태변수가 2개임. 이 경우 벡터/행렬로 모형을 표현

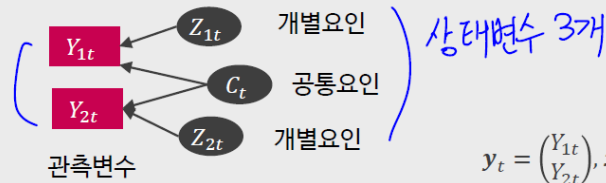
-> 각각의 오차항들은 정규분포를 따른다고 가정

#### (예7-1) 다음 모형을 일반적 형태(벡터/행렬)로 표현하라.

- (관측방정식)  $Y_t = \mu_t + \varepsilon_t$ ;  $\varepsilon_t \sim \text{Nor}(0, \sigma_\varepsilon^2)$
  - (상태방정식)  $\mu_t = \mu_{t-1} + \beta_{t-1} + a_t$ ,  $\beta_t = \beta_{t-1} + b_t$ ;  $a_t \sim \text{Nor}(0, \sigma_a^2)$ ;  $b_t \sim \text{Nor}(0, \sigma_b^2)$
- (풀이)
- 상태방정식은 다음과 같이 표현된다.
  - $\begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{pmatrix} \mu_{t-1} \\ \beta_{t-1} \end{pmatrix} + \begin{pmatrix} a_t \\ b_t \end{pmatrix}$
  - 상태변수 벡터를 정의하면
- $$\mathbf{x}_t = \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} \Rightarrow \mathbf{x}_t = \mathbf{F} \mathbf{x}_{t-1} + \mathbf{v}_t; \quad \mathbf{Q} = \begin{bmatrix} \sigma_a^2 & 0 \\ 0 & \sigma_b^2 \end{bmatrix}$$
- 관측방정식
- $$Y_t = (1 \quad 0) \begin{pmatrix} \mu_t \\ \beta_t \end{pmatrix} + \varepsilon_t; \quad \mathbf{R} = \sigma_\varepsilon^2$$
- (관측방정식)  
 $y_t = \mathbf{G} \mathbf{x}_t + \mathbf{w}_t, \quad \mathbf{w}_t \sim \text{WN}(\mathbf{0}, \mathbf{R})$
  - (상태방정식)  
 $\mathbf{x}_t = \mathbf{F} \mathbf{x}_{t-1} + \mathbf{v}_t, \quad \mathbf{v}_t \sim \text{WN}(\mathbf{0}, \mathbf{Q})$

- 상태 변수가 2개이므로, 벡터 형식으로 표현해야함
- $\mu_t$ 와  $\beta_t$ 를 결합하여  $\mathbf{x}_t$ 라는 상태변수 벡터를 정의한 것임
- $\mathbf{x}_t$ 에 대한  $\mathbf{x}_{t-1}$ 을 생각하면, 계수  $\mathbf{F}$ 에 대해 식을 쓸 수 있음
- 관측방정식은 관측 변수가 1개이므로  $y_t$ 가 상태 변수  $\mathbf{x}_t$ 로 표현됨

(예7-2) 다음 그림과 같은 모형을 고려하자.



• 관측방정식

$$Y_{1t} = \gamma_1 C_t + Z_{1t}; Y_{2t} = \gamma_2 C_t + Z_{2t}$$

• 상태방정식

- (공통요인)  $C_t = \phi C_{t-1} + v_t, v_t \sim \text{Nor}(0, 1)$
- (개별요인1)  $Z_{1t} = \alpha_1 Z_{1,t-1} + \varepsilon_{1t}, \varepsilon_{1t} \sim \text{Nor}(0, \sigma_1^2)$
- (개별요인2)  $Z_{2t} = \alpha_2 Z_{2,t-1} + \varepsilon_{2t}, \varepsilon_{2t} \sim \text{Nor}(0, \sigma_2^2)$

$$y_t = \begin{pmatrix} Y_{1t} \\ Y_{2t} \end{pmatrix}, x_t = \begin{pmatrix} C_t \\ Z_{1t} \\ Z_{2t} \end{pmatrix}$$

(관측방정식)

$$y_t = G x_t, G = \begin{bmatrix} \gamma_1 & 1 & 0 \\ \gamma_2 & 0 & 1 \end{bmatrix}$$

(상태방정식)

$$x_t = F x_{t-1} + v_t, v_t \sim \text{WN}(\mathbf{0}, Q)$$

$$F = \begin{bmatrix} \phi & 0 & 0 \\ 0 & \alpha_1 & 0 \\ 0 & 0 & \alpha_2 \end{bmatrix} Q = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \sigma_1^2 & 0 \\ 0 & 0 & \sigma_2^2 \end{bmatrix}$$

- 관측 변수가 2개인 경우임
- 각각의 관측 변수에 개별적으로 영향을 미치는 요인이 하나씩 있고 공통요인  $C_t$ 가 존재함
- 상태변수는 총 3개임

## 7-2. 칼만 필터

- 최적선형예측식: 상태공간모형에서는 미래의 값을 예측하기 위해 우선적으로 상태 변수  $x_t$ 를 예측해야 함
- 새로운 관측치가 발생할 때, 상태변수의 예측식을 예측식을 이전 예측식으로부터 갱신하는 것을 칼만 필터라고 함
- 최적선형예측식은 베이지안 기법에 의거하여, 사전확률분포로부터 사후확률분포의 기댓값과 분산을 구하는 것임

• 목적: 확률변수  $L$ 를 예측하는데 관측치  $Y$ 의 선형식 사용

• 예측식 형태:  $E[L|Y] = \alpha + \beta Y$

-  $\alpha, \beta$ : 추정필요 계수

• 계수추정을 위해 다음 제곱합 기대치 최소화

- $Q = E[(L - \alpha - \beta Y)^2]$
- $Q$ 를 풀면 다음과 같다
- $Q = \text{Var}[L] + E^2[L] + \beta^2 \{\text{Var}[Y] + E^2[Y]\} - 2\beta \{ \text{Cov}[L, Y] + E[L]E[Y] \} + \alpha^2 - 2\alpha E[L] + 2\alpha \beta E[Y]$
- $\frac{\partial Q}{\partial \alpha} = 0; \frac{\partial Q}{\partial \beta} = 0$  풀면
- $\alpha^* = E[L] - \beta^* E[Y]$
- $\beta^* = \frac{\text{Cov}[L, Y]}{\text{Var}[Y]}$

• 최적 선형예측식

- $E^*[L|Y] = \alpha^* + \beta^* Y = E[L] + \frac{\text{Cov}[L, Y]}{\text{Var}[Y]} (Y - E[Y])$
- $Q^* = \text{Var}[L] - \frac{\text{Cov}^2[L, Y]}{\text{Var}[Y]}$

## 최적선형예측식과 칼만필터

### • 최적선형예측식

$$- E[L|Y] = \alpha^* + \beta^* Y = E[L] + \frac{Cov[L,Y]}{Var[Y]} (Y - E[Y])$$

### • 시계열 $Y_t, Y_{t-1}, Y_{t-2}, \dots$ 이 있는 경우

-  $E[L|Y] = E[L|Y_t, Y_{t-1}, \dots]$ : 가장 최근 관측치  $Y_t$ 를 포함한 조건부 기대치

-  $E[L] = E[L|Y_{t-1}, \dots]$ : 최근 관측치  $Y_t$ 가 없고 과거치만의 조건부 기대치

베이지안 관점에서

-  $E[L|Y_{t-1}, \dots]$ : 사전확률분포의 기대치

-  $E[L|Y_t, Y_{t-1}, \dots]$ : 사후확률분포의 기대치

### • 아래 최적선형예측식을 칼만필터라 함

$$- E[L|Y_t, Y_{t-1}, \dots] = E[L|Y_{t-1}, \dots] + \frac{Cov[L, Y_t | Y_{t-1}, \dots]}{Var[Y_t | Y_{t-1}, \dots]} (Y_t - E[Y_t | Y_{t-1}, \dots])$$

예측값

- 주어진 시계열에 대해서, L(상태 변수)을 예측해야 함
- 가장 최근 데이터  $Y_t$ 로부터 t 시점이 포함된 경우와 그렇지 않은 경우로 나누어 L의 조건부 기대값을 구함
- 베이지안 관점에서 사전/사후확률분포를 정의함
- 사전확률분포에 예측오차의 일정 부분을 더하여 사후확률분포의 기대값을 구함

### (예7-3) 다음 모형에서 상태변수들의 칼만 필터식을 유도하라.

- (관측방정식)  $Y_t = \mu_t + \varepsilon_t, \quad \varepsilon_t \sim Nor(0, \sigma_\varepsilon^2)$
- (상태방정식)  $\mu_t = \mu_{t-1} + \beta_{t-1} + a_t, \quad a_t \sim Nor(0, \sigma_a^2)$   
 $\beta_t = \beta_{t-1} + b_t, \quad b_t \sim Nor(0, \sigma_b^2)$

### (풀이)

- 기호정의

$$l_t = E[\mu_t | Y_t, \dots], \quad m_t = E[\beta_t | Y_t, \dots]$$

$$p_t = Var[\mu_t | Y_t, \dots], \quad q_t = Var[\beta_t | Y_t, \dots], \quad r_t = Cov[\mu_t, \beta_t | Y_t, \dots]$$

- 상태변수  $\mu_t$ 의 최적선형예측식 (칼만필터)

$$l_t = E[\mu_t | Y_t, \dots] = E[\mu_t | Y_{t-1}, \dots] + \frac{Cov[\mu_t, Y_t | Y_{t-1}, \dots]}{Var[Y_t | Y_{t-1}, \dots]} (Y_t - E[Y_t | Y_{t-1}, \dots])$$

$$E[\mu_t | Y_{t-1}, \dots] = E[\mu_{t-1} + \beta_{t-1} + a_t | Y_{t-1}, \dots] = l_{t-1} + m_{t-1}$$

$$l_t = l_{t-1} + m_{t-1} + K_t^\mu (Y_t - l_{t-1} - m_{t-1}), \quad K_t^\mu = \frac{p_{t-1} + q_{t-1} + 2r_{t-1} + \sigma_a^2}{p_{t-1} + q_{t-1} + 2r_{t-1} + \sigma_a^2 + \sigma_\varepsilon^2}$$

- 상태 변수 2개에 대한 조건부 기대값을 구하는 것이 목표임
- $\mu_t, \beta_t$  각각에 대해 칼만 필터를 적용함

(예7-3 계속)

- 상태변수  $\beta_t$ 의 최적선형예측식 (칼만필터)

$$m_t = E[\beta_t | Y_t, \dots] = E[\beta_t | Y_{t-1}, \dots] + \frac{Cov[\beta_t, Y_t | Y_{t-1}, \dots]}{Var[Y_t | Y_{t-1}, \dots]} (Y_t - E[Y_t | Y_{t-1}, \dots])$$

$$= m_{t-1} + K_t^\beta (Y_t - l_{t-1} - m_{t-1}), \quad K_t^\beta = \frac{q_{t-1} + r_{t-1}}{p_{t-1} + q_{t-1} + 2r_{t-1} + \sigma_a^2 + \sigma_\varepsilon^2}$$

- 분산의 갱신 공식

$$p_t = Var[\mu_t | Y_t, \dots] = Var[\mu_t | Y_{t-1}, \dots] - \frac{Cov^2[\mu_t, Y_t | Y_{t-1}, \dots]}{Var[Y_t | Y_{t-1}, \dots]} = K_t^\mu \sigma_\varepsilon^2$$

$$q_t = Var[\beta_t | Y_t, \dots] = q_{t-1} + \sigma_b^2 - K_t^\beta (q_{t-1} + r_{t-1})$$

$$r_t = Cov[\mu_t, \beta_t | Y_t, \dots] = K_t^\beta \sigma_\varepsilon^2$$

- 일반적 상태공간모형

- (관측방정식)  $y_t = Gx_t + w_t, w_t \sim WN(0, R)$
- (상태방정식)  $x_t = Fx_{t-1} + v_t, v_t \sim WN(0, Q)$

- 상태변수 기대치 및 공분산

- 기대치 벡터:  $m_t = E[x_t | y_t, \dots]$
- 공분산행렬:  $P_t = Var[x_t | y_t, \dots]$

- 베이지안 기법

- $x_t$ 의 사전확률분포  $x_t | y_{t-1}$ 로 부터 관측치  $y_t$  발생시 사후확률분포  $x_t | y_t$  도출
- 칼만 필터 공식

$$m_t = Fm_{t-1} + K_t(y_t - GFm_{t-1})$$

$$P_t = B_t - K_tGB_t$$

$$K_t = B_tG^T(GB_tG^T + R)^{-1}, B_t = FP_{t-1}F^T + Q$$

### 7-3. 모형의 추정 및 예측

추정: MLE 방식으로 계수를 추정하고 예측함

(예 7-5) 다음의 MA(1) 모형을 상태공간모형으로 표현하고 최우추정법으로 계수 및 오차분산을 추정하라.

$$Y_t = a_t - \theta a_{t-1}, a_t \sim Nor(0, \sigma^2)$$

(풀이)

- 상태변수 정의  $x_t = \begin{pmatrix} a_t \\ a_{t-1} \end{pmatrix}$
- (관측방정식)  $Y_t = (1 \quad -\theta) \begin{pmatrix} a_t \\ a_{t-1} \end{pmatrix} \Rightarrow G = (1 \quad -\theta), R = 0$
- (상태방정식)  $\begin{pmatrix} a_t \\ a_{t-1} \end{pmatrix} = \begin{bmatrix} 0 & 0 \\ 1 & 0 \end{bmatrix} \begin{pmatrix} a_{t-1} \\ a_{t-2} \end{pmatrix} + \begin{pmatrix} a_t \\ 0 \end{pmatrix} \Rightarrow F = \begin{bmatrix} 0 & 0 \\ 1 & 0 \end{bmatrix}, Q = \begin{bmatrix} \sigma^2 & 0 \\ 0 & 0 \end{bmatrix}$
- 칼만필터식

$$m_t = E[a_t | Y_t] = \frac{\sigma^2}{\sigma^2 + \theta^2 p_{t-1}} (Y_t + \theta m_{t-1})$$

$$p_t = Var[a_t | Y_t] = \frac{\sigma^2 \theta^2 p_{t-1}}{\sigma^2 + \theta^2 p_{t-1}}$$

(예 7-5 계속)

- 관측치 조건부 기대치 및 분산

$$\begin{aligned} \mu_t &= E[Y_t | Y_{t-1}] = -\theta m_{t-1} \\ C_t &= \text{Var}[Y_t | Y_{t-1}] = \sigma^2 + \theta^2 p_{t-1} \end{aligned}$$

- 로그 우도함수

$$\begin{aligned} \log L(\mathbf{y}_1, \dots, \mathbf{y}_T) &= -\frac{Td}{2} \log 2\pi - \frac{1}{2} \sum_{t=1}^T \log |C_t| - \frac{1}{2} \sum_{t=1}^T (\mathbf{y}_t - \boldsymbol{\mu}_t)^T C_t^{-1} (\mathbf{y}_t - \boldsymbol{\mu}_t) \\ &= -\frac{1}{2} \left[ T \log 2\pi + \sum_{t=1}^T \log(\sigma^2 + \theta^2 p_{t-1}) + \sum_{t=1}^T \frac{(Y_t + \theta m_{t-1})^2}{\sigma^2 + \theta^2 p_{t-1}} \right] \rightarrow \text{최대가 되는 } \sigma^2, \theta \text{ 찾기} \end{aligned}$$

- 관측 데이터

	1	2	3	4	5	6	7	8	9	10	11	12
$Y_t$	8	10	-9	13	-5	-15	24	6	-21	20	-7	-24

- 최우추정치

초기치:  $m_0 = 0, p_0 = \sigma^2, \hat{\theta} = 0.85, \hat{\sigma}^2 = 140$

(예 7-6) 다음 모형에서 관측치를 예측하라.

- (관측방정식)  $Y_t = \mu_t + \varepsilon_t, \varepsilon_t \sim \text{Nor}(0, \sigma_\varepsilon^2)$
- (상태방정식)  $\mu_t = \mu_{t-1} + \beta_{t-1} + a_t, a_t \sim \text{Nor}(0, \sigma_a^2)$   
 $\beta_t = \beta_{t-1} + b_t, b_t \sim \text{Nor}(0, \sigma_b^2)$
- (풀이)

추정 필요

$$\begin{aligned} l_t &= E[\mu_t | Y_t, \dots], m_t = E[\beta_t | Y_t, \dots] \\ p_t &= \text{Var}[\mu_t | Y_t, \dots], q_t = \text{Var}[\beta_t | Y_t, \dots], r_t = \text{Cov}[\mu_t, \beta_t | Y_t, \dots] \\ f_{t,1} &= E[Y_{t+1} | Y_t, \dots] = l_t + m_t \\ V_{t,1} &= \text{Var}[Y_{t+1} | Y_t, \dots] = p_t + 2r_t + q_t + \sigma_a^2 + \sigma_\varepsilon^2 \end{aligned}$$